

머신러닝을 활용한 선발 투수 교체시기에 관한 연구

(A Study on the Timing of Starting Pitcher Replacement Using Machine Learning)

노성진*, 노미진**, 한무명초***, 엄선현****, 김양석**

(Seongjin Noh, Mijin Noh, Mumoungcho Han, Sunhyun Um, Yangsok Kim)

요약

본 연구는 야구 경기에서 선발 투수를 위기 상황 이전에 교체하기 위한 의사결정을 지원하는 예측 모델 구현을 목적으로 한다. 이를 위해 베이스볼 서번트(Baseball Savant)에서 제공하는 메이저리그 스탯캐스트 데이터를 활용하여, 선발 투수를 위기 상황 이전에 선제적으로 교체하는 예측 모델을 구현한다. 이를 위해 첫째, 데이터 탐색을 통해 선발 투수가 경기에서 직면하는 위기 상황을 도출하였다. 둘째, 선발 투수가 이닝 종료 전에 교체된 경우, 이전 이닝에서 교체하는 것으로 레이블을 구성하여 학습을 진행하였다. 학습된 모델을 비교한 결과 앙상블 기법을 기반으로 한 모델이 F1-Score가 65%로 가장 높은 예측 성능을 보였다. 본 연구의 실무적 의의는 제안하는 모델을 통해 선발 투수를 위기 상황 이전에 교체하여 팀의 승리 확률을 높이는 데 기여할 수 있으며, 경기 중 감독은 데이터 기반의 전략적 의사결정 지원을 받을 수 있을 것이다.

■ 중심어 : 야구 ; 선발 투수 ; 투수 교체 ; 위기 상황 ; 머신러닝

Abstract

The purpose of this study is to implement a predictive model to support decision-making to replace a starting pitcher before a crisis situation in a baseball game. To this end, using the Major League Statcast data provided by Baseball Savant, we implement a predictive model that preemptively replaces starting pitchers before a crisis situation. To this end, first, the crisis situation that the starting pitcher faces in the game was derived through data exploration. Second, if the starting pitcher was replaced before the end of the inning, learning was carried out by composing a label with a replacement in the previous inning. As a result of comparing the trained models, the model based on the ensemble method showed the highest predictive performance with an F1-Score of 65%. The practical significance of this study is that the proposed model can contribute to increasing the team's winning probability by replacing the starting pitcher before a crisis situation, and the coach will be able to receive data-based strategic decision-making support during the game.

■ keywords : Baseball ; Starting Pitcher ; Pitcher Replacement ; Crisis Situation ; Machine Learning

I. 서론

최근 다양한 스포츠 경기에서 데이터 분석은 선수나 팀의 경쟁 우위 확보를 위해 많이 활용되고 있다. 야구는 축구, 농구 등과 같은 동적인 스포츠와 달리 정적인 스포츠로 선수들을 평가하

는 지표나 경기 내에 발생할 수 있는 상황을 지표화해 놓은 대표적인 스포츠다. 따라서 야구 경기에서 생성되는 다양한 지표를 이용한 많은 연구가 진행되고 있다[1-4].

스포츠 경기의 특성상 승패는 매우 중요하다. 데이터마이닝을 활용하여 승패를 예측하는 연구가 국내외에서 진행되고 있다[5-8]. 오윤학 등은

* 학생회원, 계명대학교 경영정보학과 대학원생

** 정회원, 계명대학교 경영정보학과 교수

*** 정회원, 동국대학교 경주캠퍼스 파라미터칼리지 조교수

**** 정회원, SAS Korea

접수일자 : 2022년 03월 07일

수정일자 : 2022년 03월 23일

게재확정일 : 2022년 03월 28일

교신저자 : 김양석 e-mail : yangsok.kim@kmu.ac.kr

승패에 가장 많은 영향을 끼치는 변수가 삼진/이닝, 팀의 평균연봉, 투수의 평균 자책점 순이라는 것을 도출하였다[9]. 이처럼 야구 경기에서 가장 많은 영향을 미치는 선수는 투수다[10]. 경기에서의 투수 영향력은 투구의 속도, 유형 등과 같은 투수의 투구와 관련된 속성을 예측하는 연구로 발전되어왔다[11-13]. 투수는 수비적인 측면에서 매우 중요한 선수로서 경기의 승패에 투수의 컨디션이 많은 영향을 끼친다. 특히 투수 중에서도 가장 긴 이닝을 던지는 선발 투수의 컨디션 관리는 매우 중요하다. 선발 투수는 경기에서 처음으로 투구하는 투수를 말한다. 선발 투수는 일반적으로 가능한 긴 이닝을 투구하는 것이 요구되며 선발 투수가 승리 요건을 갖추기 위해서는 최소 5이닝을 투구해야 한다. 이처럼 많은 이닝을 소화하는 선발 투수를 교체하는 것은 감독이 내려야 하는 중요한 의사결정 중 하나이다. 컨디션이 좋은 투수가 감독의 결정에 따라 일찍 교체하게 되면 팀이 패배할 확률이 높으며 오랫동안 경기에 남아 있는 경우에도 투수가 던지는 투구 스타일이 익숙해져 상대 팀이 득점할 확률을 높일 수 있어 선행연구에서 적절한 교체 시점을 예측하는 방법을 제안하였다[14]. 하지만 선행연구에서 제시한 방법론은 선발 투수가 교체된 기준으로만 레이블을 구성하여 예측 모델을 학습시킬 때 득점 위험이 있었던 위기 상황에 교체된 경우에도 모델에 학습된다는 단점이 있다. 감독의 입장에서는 위기 상황에 선발 투수를 교체하는 것보다는 선제적으로 위기를 맞을 투수를 감지하고 이전 이닝에 교체하여 위기를 피하고 좋은 경기 흐름을 이어갈 수 있도록 하는 것이 더 나은 의사결정일 것이다.

이에 본 연구에서는 베이스볼 서번트(Baseball Savant)의 스렛캐스트 데이터를 이용하여 선발 투수를 위기 상황 이전에 교체 여부를 결정해주는 모델을 제시하고자 한다.

II. 연구 방법

1. 연구 대상

본 연구는 베이스볼 서번트(Baseball Savant)에서 제공하는 데이터를 활용하였다. 2017년 메이저리그에서 공식 투구 추적시스템을 기존의 카메라 추적시스템인 Pitch f/x에서 레이더 추적시스템인 트랙맨(Trackman)으로 변경한 것을 감안하여 객관성을 높이기 위해 데이터 수집 기간은 최근 4년간인 2017년부터 2020년까지 투수를 대상으로 수집하였다. 투수 교체가 아닌 선발 투수의 교체시기를 결정해주는 예측 모델을 제시하기 위해 선발 투수 이후의 데이터는 제외하고 연구를 진행하였다.

2. 자료 수집

본 연구를 수행하기 위해서 베이스볼 서번트(Baseball Savant)에서 제공하는 스렛캐스트 데이터를 크롤링을 통해 수집하였다. 데이터는 릴리즈 포인트, 구속, 회전수 등으로 구성된 투수 관련 변수와 타구 속도, 발사각도 등 타자 관련 변수로 구성되어 있다. 수집 기간은 2017년에서 2020년까지의 투구한 공을 기준으로 구성된 총 2,438,491개를 수집하였다.

3. 자료 탐색

본 연구는 선발 투수를 위기 상황 이전에 교체하기 위한 예측 모델을 구현하기 위해 먼저 위기 상황을 도출했다. 수집한 데이터를 탐색한 결과 선발 투수가 이닝을 마치기 전에 교체되었을 때는 이미 위기 상황이었거나 위기 상황이 지난 경우인 것을 확인할 수 있었다.

표 1. 이닝 종료 전 교체 비율과 주자 비율

구분	비율(%)
선발 투수 이닝 종료 전 교체 비율	0.41
득점권 주자 비율	0.60
주자가 있는 비율	0.85

표 1은 이닝 종료 전 교체 비율과 주자 비율을 나타낸 것으로 경기 중 선발 투수가 이닝을 마치기 전에 교체된 경우는 약 41%에 달했다. 여기서 가장 중요한 것은 교체되었을 시점에 주자의 유무로, 선발 투수가 이닝 종료 전 교체되었을 때 주자가 있었던 경우는 85%에 달한다. 이닝을 무사히 마치지 못하고 교체된 선발 투수의 경우 대부분이 주자를 남겨둔 상태에 교체가 되었으며 득점권에 주자가 있었던 경우는 60%에 달했다.

표 2. 이닝 종료 전 교체된 선발 투수의 마지막 타석 결과 비율

타석 결과 (events)	비율(%)
single	0.32
walk	0.20
double	0.12
field_out	0.10
home_run	0.08
strikeout	0.06
triple	0.01

표 2는 선발 투수가 이닝 종료 전 교체되었을 때 마지막으로 상대한 타자의 타석 결과를 탐색한 결과이다. 타석 결과 중 상위 3개가 안타(single), 볼넷(walk), 2루타(double) 순으로 나타났다. 안타, 볼넷, 2루타는 상대가 득점할 확률을 높여주는 타석 결과들로 팀의 위기 상황을 초래한다. 그리고 타석 결과 중 홈런(home_run) 비율이 8%로 삼진보다도 많은 것을 확인할 수 있다. 홈런을 칠 경우 모든 주자가 홈으로 들어오게 되며 그라운드에 주자가 없게 된다. 결과적으로 선발 투수가 이닝 종료 전 교체된 경우 득점권에 주자가 있는 비율과 홈런을 맞은 것을 고려하면 선발 투수가 이닝 종료 전에 교체된 경우에는 최소한 약 70%가 위기 상황이거나 위기 상황이 이미 지나간다는 것을 알 수 있다.

4. 데이터 전처리

수집한 데이터는 투구를 기준으로 구성되어 있다. 하지만 투구를 기준으로 교체 여부를 나타내는 레이블을 구성할 시 선발 투수가 평균적으로 100개의 공을 던지고 마지막 투구를 교체 여부를 나타내기 위해 레이블을 1로 지정하면 1의 구성 비율은 1%로 클래스가 불균형한 상태가 된다. 불균형 자료를 이용하여 이진 분류분석을 할 경우 소수집단에 대해 오분류가 증가할 수 있다[15,16]. 데이터의 불균형을 해소하기 위해 투구 기준이 아닌 이닝을 기준으로 데이터를 요약하여 클래스 불균형을 최소화함은 물론 모델의 연산량을 최소화하였다.

데이터에는 루상에 주자가 어떤 선수가 있는지를 나타내는 선수마다의 고유 인덱스로 표현되어 있다. 하지만 패턴을 찾기 위해서는 어떤 선수가 루상에 주자로 있는지 보다 주자의 유무가 중요하기에 이진법을 이용하여 각 루상에 주자의 유무만을 표현하였다.

투수가 투구한 결과들의 유형(볼, 스트라이크, 인플레이)과 타자가 친 타구 유형(그라운드 볼, 라인드라이브, 플라이 볼, 팝업)을 누계하여 이닝마다 선발 투수가 투구한 결과와 타자가 친 결과들을 표현하였고 타석 결과(삼진, 안타, 볼넷, 홈런)도 누계하여 표현하였다.

일부 구단 관계자는 투수의 구속이나 회전수가 줄어드는 것을 통해 피로의 징후를 알 수 있다고 한다[17]. 구속과 회전수와 더불어 릴리즈 포인트(x, y, z)의 변화가 선발 투수 교체에 영향을 미칠 것으로 판단하여 하위 집합에 대한 일련의 평균인 이동평균을 이용하여 전처리를 진행하였다. 선수별로 경기마다 투구하는 구속, 회전수, 릴리즈 포인트의 기준은 다르다. 따라서, 모든 선수의 구속을 평균으로 하여 투구마다의 편차를 구하는 것은 의미가 없기에 1회 때 던진 공의 구속, 회전수, 릴리즈 포인트를 기준으로 공을 던질 때 마다 평균을 계산하였다. 그리고 던진 공의 구속, 회전수, 릴리즈 포인트와 계산된 평균값을 이용

해 편차를 도출한 후 이닝별로 합산하여 데이터를 구성하였다. 식 (1)은 구속, 회전수, 릴리즈 포인트 편차를 구하는 계산식을 나타내며 최종적으로 모델 학습에 사용된 데이터는 표 3과 같다.

표 3. 학습에 사용된 데이터

번호	변수	정의
0	Pitch_type	구종
1	Events	타석 결과
2	Description	타석 세부결과
3	Zone	공이 도달한 위치
4	Stand	좌타 / 우타
5	P_throws	좌투 / 우투
6	Hit_location	볼을 터치한 첫 번째 야수의 위치
7	Balls	볼
8	Strikes	스트라이크
9	Game_year	년도
10	On_3b	3 루 주자 여부
11	On_2b	2 루 주자 여부
12	On_1b	1 루 주자 여부
13	Outs_when_up	아웃 카운트
14	Inning	이닝
15	Inning_topbot	홈 / 어웨이
16	Home_score	홈팀 점수
17	Away_score	어웨이팀 점수
18	Post_away_score	투구 이후 어웨이팀 점수
19	Post_home_score	투구 이후 홈팀 점수
20	Delta_home_win_exp	이전 타석과 현재 타석 등장 후 승리 기대치 변화
21	Delta_run_exp	투구 전과 투구 이후의 득점 기대치 변화
22	B_count	경기 동안 던진 볼의 수
23	S_count	경기 동안 던진 스트라이크의 수
24	X_count	경기 동안 던져 인플레이션 된 수
25	P_count	경기 동안 던진 투구의 수
26	GB_count	경기 동안 맞은 땅볼 수
27	Ld_count	경기 동안 맞은 라인드라이브 수
28	Fb_count	경기 동안 맞은 플라이볼 수
29	Pp_count	경기 동안 맞은 내야뜰공 수
30	KK_count	경기 동안 잡은 스트라이크 수
31	H_count	경기 동안 맞은 안타 수
32	BB_count	경기 동안 볼넷 수
33	HR_count	경기 동안 맞은 홈런 수
34	Batter_count	경기 동안 상대한 타자 수
35	Home_stadium	경기장
36	Release_speed_std	직구의 스피드 편차
37	Release_pos_x_std	직구의 x축 릴리스 편차
38	Release_pos_z_std	직구의 z축 릴리스 편차
39	Release_pos_y_std	직구의 y축 릴리스 편차
40	Release_spin_rate_std	직구의 회전 편차

5. 레이블 지정

투수 및 타자 정보가 포함되어있는 각 데이터 샘플에는 0 또는 1의 레이블이 지정된다. 투수가 다음 이닝에 계속 던지게 되면 샘플은 0으로 지정되며 현재 던지고 있는 이닝이 마지막인 경우 즉, 교체되어 다음 이닝에 던지지 못하는 경우는 1로 지정된다. 하지만 투수가 교체되는 시점을 기준으로만 레이블 구성 시 위기 상황을 맞아 교체된 경우에도 레이블이 1로 지정되어 교체 여부를 나타낸다. 위와 같은 레이블 구성은 위기 상황을 맞아 교체된 경우와 교체 타이밍이 늦어져 실점하여 위기가 이미 지난 경우에도 모델에 학습되는 한계점이 존재한다. 팀의 승리를 위해서는 선제적으로 위기를 맞을 투수를 감지하고 이전 이닝에 교체하여 위기를 맞지 않는 것이 팀의 승리에 기여할 수 있을 것이다.




그림 1. 레이블 구성방법

본 연구에서는 선제적으로 위기를 맞을 선발 투수의 교체 여부를 결정해주기 위해 그림 1과 같이 레이블을 구성하였다. 데이터 탐색을 통해 선발 투수가 이닝을 마치기 전에 교체되는 경우가 위기 상황인 경우가 많았으며 탐색한 결과를 토대로 이닝 종료 전에 교체된 선발 투수의 교체 시점을 이전 이닝에 1로 레이블을 지정하여 학습을 진행하였다. 데이터 생성 결과 83,908개의 사례가 생성되었고 레이블은 미교체(0) 66,649개, 교체(1) 16,259개로 구성되었다.

$$\text{구속, 회전수, 릴리즈 포인트 편차} = x_n - \frac{x_1 + \dots + x_n}{n} \quad (1)$$

6. 모델 설명

본 연구의 목적을 달성하기 위해 다음과 같은 다양한 알고리즘의 비교를 수행하였다.

K-NN은 학습 알고리즘이며 간단하고 직관적이다. 데이터가 주어지면 k개의 가장 가까운 데이터의 레이블에 대한 과반수 투표를 기반으로 데이터를 분류하는 모델이다.

AdaBoost는 학습 데이터에 대해 반복적으로 약한 학습기의 결과물들을 가중치를 두어 합산하여 최종 예측 모델을 생성한다. 이전 분류기로부터 잘 분류해내지 못한 데이터들의 가중치를 높여 다음 분류기에서는 수정해 줄 수 있다는 장점이 있다. 최종 분류에서는 이전에 학습하였던 약한 분류기 각각의 가중치를 합산하여 모델을 생성한다.

Gradient Boosting은 여러 의사결정모형의 예측을 종합하는 앙상블 모델이다. AdaBoost처럼 이전 분류기의 오차를 다음 분류기에 추가하지만 AdaBoost는 반복마다 가중치를 수정하는 반면 Gradient Boosting의 접근 방법은 이전 예측기에 다음 예측기를 학습시키는 모델이다.

Random Forest는 분류, 회귀 분석 등에 사용되는 모델로 다수의 결정 트리로 구성된 앙상블 학습 알고리즘이다. 각 트리는 부트스트랩 방법을 통해 데이터를 생성하고 생성된 데이터를 통해 훈련한다. 개별 트리들을 통해 데이터를 바라보는 관점을 다르게 해 다양성을 높인 모델이다.

Decision Tree는 분류 문제에서 많이 사용되는 모델이며 다양한 알고리즘의 기초가 되는 모델이다. 데이터를 이용해 최적의 분류를 위해 의사결정 규칙을 생성하며 의사결정 규칙을 트리 구조로 나타내주는 모델이다.

Logistic Regression은 이진 분류를 위한 회귀 기반의 모델링 기법이다. 선형 결합으로 레이블을 설명하는 관점에서는 선형 회귀 분석과 유사하지만 레이블을 특정 분류로 나누어주는 분류 모델이다.

Neural Network는 뉴런 간의 연결이 인간의

중추 신경을 모방하는 생물학적 프로세스에서 영감을 얻은 통계학적 학습 알고리즘이다. 비선형적 문제를 파악하기 위해 입력 레이어, 출력 레이어 및 여러 은닉 레이어로 구성된다.

7. 모델 평가

표 4. 선발 투수 교체 여부 혼동행렬

		예측	
		미교체(0)	교체(1)
실제	미교체(0)	TN	FP
	교체(1)	FN	TP

데이터는 무작위 샘플링을 하여 데이터의 70%를 예측 모델의 학습에 활용하였으며 나머지 30%는 테스트 데이터로 활용하였다. 모델 성능에 이용한 평가지표는 정확도와 F1-Score를 이용하였다. 정확도는 테스트 데이터에서 예측값 결과와 실제 값이 동일한 정도를 나타낸다. F1-Score는 정밀도와 재현율의 값을 조화평균내서 하나의 수치로 나타낸 지표이며 불균형 데이터를 평가할 때 정확하게 성능을 알 수 있는 장점이 있다. 식 (2)~(5)는 혼동행렬을 바탕으로 산출한 예측 모델의 성과지표이다.

$$\text{정확도} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

$$\text{재현율} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{정밀도} = \frac{TP}{TP + FP} \quad (4)$$

$$F1-Score = 2 \times \frac{\text{Precision} + \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5)$$

III. 연구 결과

1. 교체 예측 모델 결과

본 연구에서 선발 투수를 위기 이전에 교체 여부를 결정해주는 각 모델의 성능은 표 5와 같다. Decision Tree와 Neural Network를 제외한 모

표 5. 교체 예측 모델 결과

모델	정확도	재현율	정밀도	F1-Score
K-NN	0.87	0.53	0.73	0.61
AdaBoost	0.88	0.56	0.75	0.64
Gradient Boost	0.88	0.57	0.76	0.65
Random Forest	0.88	0.55	0.76	0.64
Decision Tree	0.84	0.55	0.58	0.57
Logistic Regression	0.88	0.57	0.73	0.64
Neural Network	0.86	0.37	0.8	0.5

텔의 성능은 큰 차이가 없는 것으로 나타났다. Decision Tree는 정확도가 84%로 모델 중 가장 낮았으며 F1-Score 57%로 낮게 나타났다. Neural Network는 정확도 86%로 높게 나타난 것을 확인할 수 있지만 F1-Score 50%로 모델 중에서 가장 낮은 성능을 나타냈다. 성능이 낮은 이유는 재현율이 37%로 다른 모델에 비해 현저히 낮은 성능을 보여주기 때문이며 정밀도가 80%로 높은 것을 보아 모델의 학습이 편향되어 소수 집단의 오분류가 높아진 것을 확인할 수 있다. 이는 선발 투수의 교체 시점을 예측하는 데 있어 신경망 기반의 모델을 사용하는 것은 어려움이 있음을 시사한다.

반면 Gradient Boost, AdaBoost, Random Forest는 모델 중 성능이 가장 우수한 것으로 나타났다. Gradient Boost는 F1-Score 65%로 가장 성능이 높은 것으로 나타났으며 AdaBoost, Random Forest는 F1-Score 64%로 나타났다. 예측 모델의 성능을 모두 측정한 결과 앙상블 기법의 모델이 다른 모델들에 비해 우수한 성능을 보여주는 것으로 나타났으며 배깅 및 부스팅 기반 방법의 매개변수 조정을 통해 분류 성능을 더욱 향상시킬 수 있을 것이다.

2. 변수 중요도

본 연구에서 선발 투수를 위기 상황 이전에 교체하는 분류 문제에 있어 중요한 변수를 도출한 결과는 그림 2와 같다. 상위에 있는 변수들을 살펴보면 'P_count', 'B_count', 'Batter_count' 순으로 교체 여부에 있어 중요한 변수인 것을 확인할 수 있다. 'P_count'와 'Batter_count'가 중요한 변

수로 선행연구와 유사하게 나타났으며 'B_count'가 선행연구와는 다르게 변수 중요도가 높게 나타난 것을 확인할 수 있다.




그림 2. Feature Importance of RF

IV. 논 의

선행연구에서 사용된 연구 방법은 선발 투수의 체력적인 문제, 선발 투수의 교체 시 감독의 경험적 기반이 아닌 데이터 접근 방식에 중점을 두었으며, 선발 투수의 적절한 교체시기만을 결정해주고자 하였다. 이와 같은 방법론은 경기에서 전략적인 우위를 점하기 힘들다는 한계점이 존재한다. 이에 본 연구에서는 선행연구의 한계점을 바탕으로 선발 투수를 위기 상황 이전에 교체 여부를 결정해주는 모델을 제시하였고 다양한 머신러닝 알고리즘을 활용하였다. 학습된 예측 모델별 성능을 측정한 결과 선행연구와 같이 앙상블 기법의 모델이 가장 성능이 높은 것으로 나타났으며 이를 통해 선발 투수의 교체시기를 예측하는 문제는 대체로 앙상블 기법이 좋은 성능을 보여주는 것으로 나타났다. 본 연구에서 구축한 모델의 F1-Score가 65%로 일반적인 분류 문

제를 예측하는 모델의 성능과 비교하였을 때 높은 편이 아니다. 이는 본 연구의 연구 결과를 비롯하여 F1-Score가 53%로 나온 선행연구를 고려하였을 때 선발 투수의 교체시기를 예측하는 문제가 전반적으로 좋은 성능을 보이는 데 어려움이 있는 것으로 판단된다.

본 연구는 모델의 예측 성능을 높이기 위해 선행연구와는 다르게 최신의 기술로 데이터를 수집하여 제공하는 베이스볼 서버트(Baseball Savant)의 스탯캐스트 데이터를 활용하였으며 본 연구에서 제시한 방법론을 통해 예측 모델의 성능을 향상시켰다. 선행연구와 비교하여 모델의 성능에 영향을 끼친 변수 중 다른 점은 선발 투수가 경기 동안 던진 볼의 수(B_count)이다. 선발 투수를 교체하는 시기만을 예측하는 선행연구에서는 볼의 수가 큰 영향을 끼치지 않는 것으로 보이나 본 연구에서는 볼의 수(B_count)가 변수 중요도에서 두 번째로 높은 변수로 나타났다. 투수가 볼을 전략적으로 던지는 경우도 있지만 제구가 되지 않아 볼을 던지는 경우도 있다. 볼은 팀의 입장에서는 불리한 지표이다. 또한 변수 중요도에서 볼의 수(B_count)가 높은 영향을 준다는 결과를 통해 제구 불안정으로 인한 볼의 영향이 클 것으로 보인다. 즉, 선발 투수가 위기 상황에 빠지기 전에 볼의 수에서 변화를 보이는 것을 시사한다. 변수 중요도에 상위 변수 중 투구 수(P_count)와 상대한 타자의 수(Batter_count)는 선행연구와 동일하게 중요한 변수로 나타났다. 위기 상황 이전에 선발 투수를 교체해주기 위한 예측 모델이지만 선발 투수를 교체하는 것이 근본적인 문제이므로 투구 수(P_count)와 상대한 타자의 수(Batter_count)가 동일하게 중요한 변수로 나타난 것으로 보이며 선발 투수가 아무리 좋은 공을 투구하더라도 투구 수를 한계 이상까지 던지지 못하기에 당연한 결과로 보인다. 나아가 본 연구에서는 구단에서 투수의 구속이나 회전수의 차이를 통해 피로의 징후를 알 수 있다는 내용을 바탕으로 이동평균을 이용하여 직구의

속도, 회전수, 릴리즈 포인트의 변화량을 구하여 활용하였다. 전력 투구를 하는 구원 투수와 달리 완급 조절해야 하는 선발 투수는 교체에 있어 피로도가 크게 관여할 것으로 판단되었다. 하지만 모델을 통해 변수 중요도를 도출한 결과 구속, 회전수, 릴리즈 포인트의 변화량이 중요하지 않은 것으로 나타났다. 변화량의 차이를 구함에 있어 투수가 던지는 구종 중 직구라는 하나의 구종만을 선택했다. 여러 가지 구종을 기준으로 변화량을 측정하지 않아 생긴 문제라고 생각할 수 있지만 투수가 가장 많이 던지는 구종이 직구이므로 직구가 아닌 다른 구종으로 변화량을 측정하여도 똑같은 결과가 나올 것으로 판단된다. 변화량의 측정 방식의 문제인 것으로 예상되며 투수의 구속이나 회전수의 차이가 피로도와 관계를 증명하는 향후 연구가 진행될 필요가 있다.

V. 결 론

본 연구는 머신러닝을 통해 위기 상황을 맞을 선발 투수를 선제적으로 감지하고 이전 이닝에서 교체함으로써 팀의 승리와 팀 순위 상승에 기여할 수 있는 예측 모델을 제시하였다. 모델은 앙상블 기법이 가장 성능이 좋은 것으로 나타났으며 변수 중요도를 확인해본 결과 선행연구와 다르게 투수가 던진 볼의 수(B_count)가 높게 나온 것을 통해 선발 투수가 위기에 빠지지 않으려면 볼의 수도 함께 관리하여야 함을 시사한다. 일반적으로 분류 모델을 활용하여 연구한 모델의 성능만큼 본 연구의 예측 모델의 성능이 다소 높지 않다는 것을 알 수 있다. 하지만 선행연구의 평가지표 수치를 감안하였을 때 선발 투수 교체 시기를 예측하는 분류 문제가 좋은 예측력을 가지기에는 어려움이 많은 문제임을 알 수 있다. 또한, 대부분의 스포츠 경기에서 팀의 순위가 단 몇 경기의 차이로 결정되어 온전히 성능으로만 예측 모델을 평가하기가 어렵다. 즉, 모든 경기에서 모든 위기 상황을 모면하는 것은 어려우나 단

몇 경기만이라도 위기 상황을 모면할 수 있다면 팀의 순위는 크게 바뀔 수 있을 것이다. 이는 본 연구에서 제시한 예측 모델을 감독이 경기 중 위기 상황이 오기 전 선발 투수를 교체하는 전략적인 의사결정을 위해 충분히 활용할 수 있다는 것을 말한다.

REFERENCES

- [1] G. Ganeshapillai, J. Guttag, "A data-driven method for in-game decision making in MLB," *MIT SSAC*, 2014.
- [2] M. Fichman, M. Fichman, "From darwin to the diamond: How baseball and billy beane arrived at moneyball," *Available at SSRN*, 2012.
- [3] T. Ishii, "Using machine learning algorithms to identify undervalued baseball players," *Technical Report: Stanford University*, 2016.
- [4] 박동주, 김병우, 정영선, 안창욱 "Deep Neural Network 기반 프로야구 일일 관중 수 예측 : 광주-기아 챔피언스 필드를 중심으로," *스마트미디어저널*, 제7권, 제1호, 16-23쪽, 2018년 3월
- [5] 김원중, 최연식, 유동희, "데이터 마이닝을 활용한 한국 프로야구 구단의 승패예측과 승률 향상을 위한 전략 도출 연구," *한국스포츠산업경영학회지*, 제23권, 제3호, 88-104쪽, 2018년 6월
- [6] C.S. Valero, "Predicting Win-Loss outcomes in MLB regular season games - A comparative study using data mining methods," *International Journal of Computer Science in Sport*, vol. 15, no. 2, pp. 291-112, 2016.
- [7] B. Tolbert, T. Trafalis, "Predicting major league baseball championship winners through data mining," *Athens Journal of Sports*, vol. 3, no. 4, pp. 239-252, 2016.
- [8] B. Everman, "Analyzing baseball statistics using data mining," Jan. 2015.
- [9] 오윤학, 김한, 윤재섭, 이종석, "데이터마이닝을 활용한 한국프로야구 승패예측모형 수립에 관한 연구," *대한산업공학회지*, 제40권, 제1호, 8-17쪽, 2014년 2월
- [10] 이장택, "한국프로야구에서의 투수평가지표," *한국 데이터정보과학회지*, 제25권, 제3호, 485-492쪽, 2014년 5월
- [11] P. Yifan, "Predict Next Baseball Pitch Type with RNN"
- [12] G.D, Sidle, "Using multi-class machine learning methods to predict major league baseball pitches," *North Carolina State University*, 2017.
- [13] P. Hoang, M. Hamilton, J. Murray, C. Stafford and H. Tran, "A dynamic feature selection based LDA approach to baseball pitch prediction," *Springer*, pp. 125-137, 2015.
- [14] M. Woodham, J. Hawkins, A. Singh, S. Chakraborty, "When to Pull Starting Pitchers in Major League Baseball? A Data Mining Approach," *2019 18th IEEE International Conference On Machine Learning And Applications (ICMLA)*, FL, USA, pp. 426-431, 2019.
- [15] 김강민, 김판구, 전찬준, "Deep Metric Learning을 활용한 합성곱 신경망 기반의 피부질환 분류 기술," *스마트미디어저널*, 제10권 제4호, 45-53쪽, 2021년 12월
- [16] 유병주, "불균형 자료의 분류분석 방법별 성능 비교와 접근 전략 연구," *Journal of The Korean Data Analysis Society*, 제23권, 제1호, 195-207쪽, 2021년 2월
- [17] Keith Law, SMART BASEBALL, 두리반, 4-352 쪽, 2020년

저 자 소 개



노성진(준회원)

2021년 계명대학교 경영정보학과 학사 졸업.

2021년 계명대학교 경영정보학과 석사 재학.

<주관심분야 : 빅데이터분석, 인과추론>



노미진(정회원)

1999년 대구가톨릭대학교 경영학사 졸업.

2001년 경북대학교 경영학과 경영정보 전공 석사 졸업.

2006년 경북대학교 경영학과 경영정보 전공 박사 졸업.

<주관심분야 : 빅데이터분석, 데이터 시각화>



한무명초(정회원)

2006년 방송통신대학교 컴퓨터과학학과 학사 졸업.

2009년 계명대학교 전산교육학과 석사 졸업.

2016년 계명대학교 경영정보학과 박사 졸업.

<주관심분야 : 데이터마이닝, 정보기술, 지식관리, 컴퓨팅사고>



엄선현(정회원)

2020년 계명대학교 경영정보학과 학사 졸업.

2022년 계명대학교 경영정보학과 석사 졸업.

2021년~ SAS Korea 재직.

<주관심분야 : Health Care, Machine Learning and Data Analytics, Deep Learning>



김양석(정회원)

1995년 서울시립대학교 경제학과 학사 졸업.

2004년 University of Tasmania 컴퓨터 공학 석사 졸업.

2009년 University of Tasmania 컴퓨터 공학 박사 졸업.

<주관심분야 : Machine Learning and Data Analytics, Recommender Systems, Knowledge Engineering>