



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位 請求論文

指導教授 片炫雄, 金承燦

스텟캐스트와 딥러닝을 활용한
MLB 투수 부상 예측에 관한 연구

成均館大學校 一般大學院

스포츠인터랙션사이언스 學科

孫 敏 起

碩士學位請求論文

M스
L택
B캐
투스트
수트
부와
상
예
측
에
관
한
연
구
연구
활
용
한

2
0
2
3

孫
敏
起

碩士學位 請求論文

指導教授 片炫雄, 金承燦

스탯캐스트와 딥러닝을 활용한
MLB 투수 부상 예측에 관한 연구

A Study on Predicting MLB Pitcher Injuries Using
Statcast and Deep Learning

成均館大學校 一般大學院

스포츠인터랙션사이언스 學科

孫 敏 起

碩士學位 請求論文

指導教授 片炫雄, 金承燦

스탯캐스트와 딥러닝을 활용한
MLB 투수 부상 예측에 관한 연구

A Study on Predicting MLB Pitcher Injuries Using
Statcast and Deep Learning

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2023 年 4 月 日

成均館大學校 一般大學院

스포츠인터랙션사이언스 學科

孫 敏 起

이 論文을 孫 敏 起의 工學
碩士學位 論文으로 認定함.

2023 年 6 月 日

審査委員長

審査委員

審査委員

審査委員

목차

제1장 서론	1
1. 연구의 필요성과 배경	1
2. 연구의 목적	3
제2장 이론적 배경	4
1. 메이저 리그 베이스볼(Major League Baseball, MLB)	4
2. 스탯캐스트(Statcast)	6
3. 부상자 명단(Injured List, IL)	7
4. 딥러닝(Deep Learning, DL)	9
5. 차원 축소 기법(Dimensionality Reduction)	14
6. 커널 밀도 추정(Kernel Density Estimation, KDE)	15
7. 선행연구	15
제3장 데이터 분석 및 전처리	18
1. 데이터 수집	18
2. 데이터 탐색	20
3. 데이터 전처리 및 피처 엔지니어링	30
제4장 연구방법 및 평가	39
1. 예측모델 수립	39
2. 예측모델 평가	46
3. 예측모델 결과	52

제5장 논의	63
1. 연구 결과 요약	63
2. 유사 연구와의 비교	66
3. 정확도가 낮은 이유에 대한 분석	68
제6장 결론 및 제언	69
참고문헌	71
1. 국내문헌	71
2. 외국문헌	71
3. 기타참고자료	74
ABSTRACT	76

표목차

표 1. 메이저 리그 베이스볼(MLB) 구단 리스트	5
표 2. 부상자 명단 종류별 주요 적용 제도	8
표 3. 연구에 사용할 Statcast 데이터 요인	21
표 4. 부상 종류 분류 (스포츠랙 기준)	26
표 5. 부상위험도가 높은 상위 10개 부상 종류	28
표 6. 예측변수 클래스 설정 방식	33
표 7. 예측에 사용한 입력변수 및 예측변수 종류	40
표 8. RandomOverSampler 적용 전·후의 학습데이터 내 클래스 사이즈 비교	43
표 9. 예측모델 실험 케이스 분류	47
표 10. 하이퍼파라미터 튜닝 케이스	48
표 11. 각 케이스별 하이퍼파라미터 조정에 따른 성능 결과 비교	53
표 12. [Case 1] Classification Report	54
표 13. [Case 2] Classification Report	55
표 14. [Case 3] Classification Report	57
표 15. [Case 4] Classification Report	58
표 16. [Case 5] Classification Report	60
표 17. [Case 6] Classification Report	61
표 18. 선행연구 & 본 연구 간 결과 비교	66

그림목차

그림 1. 2017시즌~2022시즌 MLB 투수 부상자 명단 등재 횟수 추이	2
그림 2. Binary Classification with Decision Boundary	12
그림 3. 베이스볼 서번트 스탯캐스트 data 제공 서비스	18
그림 4. 스포트랙의 MLB 선수 부상자 명단 제공 서비스	19
그림 5. 연도별 평균 출전 횟수 및 경기별 평균 투구 수	22
그림 6. 연도별 평균 release speed, vy0, release spin rate, release pos z	23
그림 7. 2017시즌~2022시즌 부상자명단 등재 월별 분포	25
그림 8. 2017시즌~2022시즌 부상자 명단에 등재된 부상 종류별 집계	27
그림 9. 연도별 전체부상과 상제 주요 부상 비중을 나타내는 히스토그램	29
그림 10. PCA 3D 및 t-SNE 3D 결과	34
그림 11. 전체 투수 대상 커널밀도추정 (bandwidth = 0.5)	37
그림 12. 부상 경험이 가장 많은 투수 대상 커널밀도추정 (bandwidth = 0.5)	38
그림 13. MLB 투수 상제 주요 부상 예측 모델 개발 도식	39
그림 14. RandomOverSampler 작동 방식	43
그림 15. FFNN 모델 아키텍처(Model Achitecture)	44
그림 16. [Case 1] (좌) Confusion Matrix, (우) ROC Curve & AUC	54
그림 17. [Case 2] (좌) Confusion Matrix, (우) ROC Curve & AUC	56
그림 18. [Case 3] (좌) Confusion Matrix, (우) ROC Curve & AUC	57
그림 19. [Case 4] (좌) Confusion Matrix, (우) ROC Curve & AUC	59
그림 20. [Case 5] (좌) Confusion Matrix, (우) ROC Curve & AUC	60
그림 21. [Case 6] (좌) Confusion Matrix, (우) ROC Curve & AUC	62

수식목차

수식 1. Injury Risk	28
수식 2. Kernel Density Estimation	35
수식 3. MinMaxScaler	41
수식 4. Sigmoid(σ)	45
수식 5. Hyperbolic Tangent($\tanh$)	45
수식 6. Rectified Linear Unit(ReLU)	46
수식 7. Binary Cross Entropy	49
수식 8. Accuracy	50
수식 9. Precision	50
수식 10. Recall	51
수식 11. F1-Score	51
수식 12. Macro F1 Score	51

논문 요약

스탯캐스트와 딥러닝을 활용한 MLB 투수 부상 예측에 관한 연구

메이저 리그 베이스볼(Major League Baseball, MLB)에서의 투수 부상은 개인적인 경쟁력은 물론 팀 전체 성적에 부정적인 영향을 미치는 심각한 문제이다. 과거부터 투수 부상에 대한 연구는 이루어지고 있지만, 직접적으로 부상을 예측하기보다는 대부분 특정 집단을 선별한 후 부상 발생에 대한 원인을 찾고 예방을 위한 기초자료를 제시하는 데 초점이 맞춰져 있었다.

MLB는 2015년부터 Statcast 데이터 추적 시스템을 도입하여 다양한 투구 결과와 관련된 많은 요인들을 관찰할 기회를 제공하고 있다. 본 연구의 목적은 Statcast가 제공하는 방대한 투구 데이터를 활용하여, 투수들이 잠재적 부상 위험에 처해 있는지를 예측하는 딥러닝 모델을 개발하는 것이다.

연구 결과, 이전 연구에서 거의 사용하지 않았던 ‘투구의 수평 이동량과 수직 이동량, 투구 발사점의 위치와 속도(릴리스 포인트 및 릴리스 스피드), 스트라이크 존 내외에서의 투구 위치 및 회전율’과 같은 정보를 바탕으로, 투수가 해당 경기를 치른 후 향후 5경기 이내에 부상자 명단에 등재될 확률을 예측하는 딥러닝 모델을 개발하였다. 또한, 본 연구에서는 투수의 과거 부상 이력과 같은 중요한 정보를 고려하여 각각의 상황에서 최적의 예측 성능을 도출할 수 있도록 여섯 가지 케이스를 분류하여 모델을 구축하였다.

모델이 투수 부상 여부를 정확하게 예측할 확률을 나타낸 ‘정확도(Test Accuracy)’에서는 ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가

94.7%로 가장 높았다. 그다음으로 ‘Case 5’ 팔꿈치 부상 경험 선수일 때 93.6%, ‘Case 3’ 어깨 부상 경험 선수일 때 93.3%, ‘Case 2’ 상체 주요 부상 경험 선수일 때 93.1%, ‘Case 4’ 팔 부상 경험 선수일 때 92.1%, ‘Case 1’ 전체 투수 대상일 때 90.7% 순으로 나타났다.

클래스 불균형 문제를 다루는 데 유용한 ‘매크로 F1 점수(Macro F1-Score)’에서는 ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 가장 높은 0.741을 보였으며, 그다음으로는 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때 0.693, ‘Case 4’ 팔 부상 경험 선수 대상일 때 0.681, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 0.647, ‘Case 3’ 어깨 부상 경험 선수 대상일 때 0.624, ‘Case 1’ 전체 투수 대상일 때 0.607 순으로 나타났다.

마지막으로, 분류 모델의 성능을 평가하는 중요한 도구인 ‘ROC 곡선과 AUC를 이용한 평가’에서도 ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 0.93으로 가장 높은 AUC 값을 보였고, 이어서 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때 0.86, ‘Case 4’ 팔 부상 경험 선수 대상일 때 0.85, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 0.83, ‘Case 1’ 전체 투수 대상일 때 0.81, ‘Case 3’ 어깨 부상 경험 선수 대상일 때 0.80으로 나타났다.

본 논문에서 제시한 모델은, 향후 더욱 정밀한 투수 부상 예측 모델 개발에 도움이 될 수 있을 것이다. 특히 본 모델은 MLB 선수 관리자와 팀의 주요관계자들이 쉽게 수집할 수 있는 투구데이터를 바탕으로 부상 예측 모델을 연구했다는 것에 큰 의의가 있다. 본 연구는 딥러닝과 Statcast 데이터를 활용한 새로운 부상 예측 방법론을 제시하였으며, 이는 앞으로의 MLB 투수 부상 관리와 전략 수립에 있어서 중요한 변화를 불러올 것이라 기대한다.

주제어 : 투수 부상 예측, 스탯캐스트, 지도학습, 딥러닝, FFNN, 데이터 불균형

제1장 서론

1. 연구의 필요성과 배경

야구는 각각 9명의 선수로 구성된 두 팀이 9회 동안 교대로 공격과 수비를 하는 경기로, 투수가 먼저 공을 던지면 타자가 배트를 이용하여 공을 치게 되고 1루, 2루, 3루 베이스를 순서대로 밟아 홈베이스까지 지나게 되면 득점하게 되는 구기종목이다.

야구는 전 세계적으로 많은 인기와 높은 경제성을 가진 스포츠이다. 1982년에 출범한 한국 프로야구는 국내에서 가장 많은 사랑을 받는 프로스포츠로 자리매김하였고, 1934년에 출범한 일본 프로야구(Nippon Professional Baseball, NPB)는 경기당 3만 명 이상의 평균 관중 수를 자랑하는 일본 최고의 프로스포츠 리그로 인정받고 있다. 무엇보다도, 세계 최고의 야구 리그로 알려진 메이저 리그 베이스볼(Major League Baseball, MLB)은 연간 약 7,000만 명의 관중이 경기장을 찾을 뿐만 아니라 2019년 한해 약 107억 달러의 수익을 창출해냈는데, 이는 미국 프로농구(National Basketball Association, NBA)나 영국 프리미어리그(England Premier League, EPL)보다도 더 큰 수익 규모였다.

“야구는 투수 놀음이다.”라는 말처럼, 야구 경기에서는 공을 던지는 포지션인 투수의 역할이 매우 중요한데, 이용수, 김용래, 임태홍 (2015) 및 변경석 (2019)의 연구에 따르면, 투수의 성공적인 투구 여부가 경기 흐름을 좌우하며 팀의 승패를 결정짓는 중요한 요인이기 때문에, 구단들은 팀 승리를 이끌어 줄 유망한 투수 영입

을 위해 늘 경쟁한다고 하였다. 강현민, 이현섭 (2020)은 기업이 근로자를 채용할 때와 마찬가지로, 프로스포츠 구단도 선수와 연봉 계약을 체결할 때 해당 선수가 뛰어난 역량을 꾸준히 발휘해 주기를 기대한다. 위와 같은 이유로, 투수는 타자보다 상대적으로 더 높은 조건으로 연봉 계약을 체결하고, 고용주인 구단은 투수에게 지급하는 비용보다 더 좋은 경기력을 기대하게 된다.

하지만 반대로 투수가 기대했던 실력에 비해 제 몫을 해내지 못한다면 팀은 경쟁력에서나 경제적으로 큰 타격을 입게 되는데, 그중 가장 큰 리스크(Risk)는 부상이다. 특히 투수가 치명적인 부상을 입게 되면, 본인의 선수 생명 위협은 물론이고, 구단은 팬 이탈, 전력 약화, 대체 선수에 대한 추가적 비용 발생 등의 막대한 손실을 감당해야 한다.

하지만 <그림 1>과 같이, 투수 부상은 여전히 빈번하게 발생하고 있는데, 2017시즌부터 2022시즌까지의 MLB 투수 부상자 명단 등재 횟수를 살펴보면, 코로나로 축소 운영된 2020시즌을 제외하고 매년 350건 이상으로 등재된 것을 확인할 수 있으며, 특히 2021시즌에는 571건, 2022시즌에는 490건으로 2017시즌의 359건보다 많이 증가한 수치를 나타내었다. 시즌별로 활동하는 투수의 숫자가 350명 내외인 것을 고려한다면, 투수 부상은 매우 빈번히 발생한다는 것을 파악할 수 있다.




그림 1 2017시즌~2022시즌 MLB 투수 부상자 명단 등재 횟수 추이

2. 연구의 목적

본 연구에서는 스탯캐스트에서 제공하는 세분화된 투구데이터와 부상데이터를 함께 분석하여, 투수의 부상이 예상될 시 부상 이전에 교체 및 적절한 조치를 하기 위한 효과적인 의사결정 모델 개발을 목적으로 한다. 딥러닝(Deep Learning, DL)의 한 방법론인 순방향 신경망(Feedforward Neural Network, FFNN)을 활용하여, 투수의 투구 패턴에서 일정한 변화를 감지하고, 이를 통해 잠재적인 부상으로부터 적절하게 대응하는 모델을 개발하는 것이 본 연구의 주요 목표이다. 연구 결과를 통해 구단은 투수를 부상 지점까지 두는 대신 적절한 휴식을 제공하거나 투구 스타일을 조정하는 등 투수 부상을 더욱 체계적으로 관리할 수 있을 것이며, 이를 통해 투수 개인의 안전 보장은 물론, 팀의 경쟁력을 유지하고 개선하는 도구로 활용될 수 있을 것으로 기대한다.

제2장 이론적 배경

1. 메이저 리그 베이스볼(Major League Baseball, MLB)

메이저 리그 베이스볼은 아메리칸 리그(AL : Americal League)와 내셔널 리그(NL : National League)로 구성된 미국 프로야구 최상위 리그이자 세계 최고 프로야구 리그를 뜻한다. 2월 중순에 시작하는 시범 경기인 스프링 트레이닝 이후 정규시즌이 시작되는데 시즌 중간 지점에 올스타전이 개최된다. 정규시즌 종료 후 가을야구인 포스트시즌을 거쳐 11월 초 최종 우승자를 가리게 된다. <표 1>과 같이, MLB는 아메리칸 리그 및 내셔널 리그 모두 각 15개 팀으로 총 30개 팀이 등록되어 있다. 또한 각 리그는 동부, 서부, 중부 3개의 지구로 구별되어 있는데, 한 지구에는 5개 팀이 소속되어 있다.

한 팀은 정규시즌 동안 총 162게임을 치르게 되는데 정규시즌이 종료되고 나면, 포스트시즌을 진행하게 된다. 포스트시즌에 진출할 수 있는 팀은 총 10개 팀으로 정규시즌에서 각 리그의 지구별 1위를 차지한 6개 팀과 와일드카드 지위를 얻은 4개 팀(각 리그에서 지구별 1위 팀을 제외한 나머지 팀들을 단순 승률로 줄을 세워 1, 2위인 팀)이 포스트시즌을 치르게 된다. 포스트시즌 1라운드를 디비전 시리즈(아메리칸 리그 디비전 시리즈, 내셔널 리그 디비전 시리즈), 2라운드를 챔피언십 시리즈(아메리칸 리그 챔피언십 시리즈, 내셔널 리그 챔피언십 시리즈)라고 부르고 여기서 우승하는 팀이 리그챔피언이 된다. 그리고 각 리그의 1위 팀들은 7전 4선승제의 월드시리즈를 치르게 되며, 최종 우승자가 월드챔피언이 된다.

리그	지구	팀명(약칭)	연고지
아메리칸 리그 (AL)	동부	뉴욕 양키스 (NYY)	뉴욕주 뉴욕
		보스턴 레드삭스 (BOS)	매사추세츠주 보스턴
		볼티모어 오리올스 (BAL)	메릴랜드주 볼티모어
		탬파베이 레이스 (TB)	플로리다주 세인트피터즈버그
		토론토 블루제이스 (TOR)	온타리오주 토론토
	중부	디트로이트 타이거스 (DET)	미시간주 디트로이트
		미네소타 트윈스 (MIN)	미네소타주 미니애폴리스
		시카고 화이트삭스 (CHW)	일리노이주 시카고
		캔자스시티 로변수스 (KC)	미주리주 캔자스시티
		클리블랜드 가디언스 (CLE)	오하이오주 클리블랜드
	서부	로스앤젤레스 에인절스 (LAA)	캘리포니아주 애너하임
		시애틀 매리너스 (SEA)	워싱턴주 시애틀
		오클랜드 애슬레틱스 (OAK)	캘리포니아주 오클랜드
		텍사스 레인저스 (TEX)	텍사스주 알링턴
		휴스턴 애스트로스 (HOU)	텍사스주 휴스턴
내셔널 리그 (NL)	동부	뉴욕 메츠 (NYM)	뉴욕주 뉴욕
		마이애미 말린스 (MIA)	플로리다주 마이애미
		애틀랜타 브레이브스 (ALT)	조지아주 컴벌랜드
		워싱턴 내셔널스 (WAS)	워싱턴 D.C.
		필라델피아 필리스 (PHI)	펜실베이니아주 필라델피아
	중부	밀워키 브루어스 (MIL)	위스콘신주 밀워키
		세인트루이스 카디널스 (STL)	미주리주 세인트루이스
		시카고 컵스 (CHC)	일리노이주 시카고
		신시내티 레즈 (CIN)	오하이오주 신시내티
		피츠버그 파이리츠 (PIT)	펜실베이니아주 피츠버그
	서부	로스앤젤레스 다저스 (LAD)	캘리포니아주 로스앤젤레스
		샌디에이고 파드리스 (SD)	캘리포니아주 샌디에이고
		샌프란시스코 자이언츠 (SF)	캘리포니아주 샌프란시스코
		애리조나 다이아몬드백스 (ARZ)	애리조나주 피닉스
		콜로라도 로키스 (COL)	콜로라도주 덴버

표 1 메이저 리그 베이스볼(MLB) 구단 리스트

정규시즌부터 월드시리즈 챔피언 결정까지 팀 승리를 위해 투수의 역할은 매우 중요한데, 이들은 매 경기마다 팀의 전략과 경쟁력을 좌우하는 핵심 역할을 담당하게 된다.

그러나 <그림 1>에서 확인한 것처럼, MLB에서 투수의 부상은 매우 흔하게 발생하고 있으나, 투수 부상에 관한 연구는 그 위험성에 비해 상대적으로 부족한 편이다. 투수 부상이 발생하면 선수에게 치명적인 것은 물론이고, 주요 투수가 빠지게 되어 팀의 경쟁력이 크게 하락하며, 시즌 성적 부진과 구단의 재정적 손실까지 이어질 수 있다. 이러한 이유로, 투수의 부상 위험 신호를 조기에 발견해내는 일은 MLB에서 매우 중요한 과제이며, 연구의 가치가 높을 수밖에 없다.

2. 스탯캐스트(STATCAST)

MLB.com에 따르면, 스탯캐스트는 과거에는 불가능했던 방식으로 방대한 양의 야구 데이터를 수집하고 분석할 수 있는 최첨단 추적 기술이라 설명한다. 2006년, MLB는 모든 MLB 경기장에 Pitch f/x를 설치하여 MLB 경기장에서 기록된 모든 투구 속도를 추적할 수 있는 기능을 제공할 수 있게 되었다. 2015년 이후부터는 경기장 전체에 걸쳐 모든 선수와 공을 추적할 수 있는 새로운 기술인 스탯캐스트(Statcast)가 등장하게 되면서, 경기의 모든 데이터를 추적할 수 있게 되었다.

스탯캐스트가 제공하는 데이터로는 투구(구종, 속도, 회전 속도 및 방향, 움직임), 타격(출구 속도, 발사 각도, 타구 거리), 주루(스프린트 속도, 출루 시간), 수비(팔 강도, 캐치 확률, 포수) 데이터와 경기 일자, 경기 타입, 주자 여부 등 투구 1개당 총 92개 요인을 제공하며, 'baseballsavant.mlb.com'에서 'Statcast Search' 기능을 통해 구단이나 방송, 팬 등이 고급 데이터를 쉽게 활용하고 즐길 수 있도록 모든 데이터를 공개하고 있다.

특히, 스탯캐스트는 야구 분야 발전을 위한 연구에 많이 활용되고 있는데, Alvarado, A et al. (2021)는 스탯캐스트 데이터를 바탕으로 변화구의 회전율과 타자의 타율 사이의 연관성에 관한 연구를 하였고, LaPrade, C. M et al. (2022)은 부상 후 MLB 투수들의 경기력에 미치는 영향을 스탯캐스트로 분석하였다. 또한, Fury, M et al. (2021)는 스탯캐스트를 기반으로 부상 경험자 및 미경험자 데이터를 수집하고, 이항 로지스틱 회귀 분석을 사용하여 팔꿈치 내측 인대(UCL) 부상의 위험 요인을 찾아내는 연구를 수행하였다. 이처럼, 스탯캐스트는 선수 부상, 경기력 예측, 팀 전략 개발 및 스킬 분석 등 다양한 분야에서 활용되고 있으며, 기계학습과 같은 핵심기술과의 융합을 통해 앞으로 더 많은 발전과 혁신을 만들어 낼 것으로 기대된다.

3. 부상자 명단(Injured List, IL)

부상자 명단(Injured List, IL)은 MLB 선수들이 부상을 당했을 때, 출전 선수 명단(Roster)에서 제외하는 선수들의 명단을 말한다. IL 등재 시, 선수는 FA일수나 연봉에 불이익 없이 충분한 회복 기간을 보장받게 되며, 구단은 부상 선수의 공백을 다른 선수로 대체할 수 있는 유연성을 가질 수 있다. 이처럼 IL 제도는 궁극적으로 선수의 건강과 팀의 경쟁력을 동시에 보호하는 제도로 활용되고 있다.

IL 제도는 부상 정도에 따라 분류 기준을 나누어 놓았는데, 2022시즌 기준으로는 7일(7-day IL), 10일(10-day IL), 15일(15-day IL), 60일(60-day IL)로 분류하고 있다. 7-day IL은 보통 뇌진탕 증상이 있는 선수를 위한 분류이며, 10-day IL은 모든 유형의 부상에 대해 등재할 수 있는 최소 기간의 분류이다. 또한, 15-day IL은 2022시즌부터 적용되는 분류 기준으로, 10-day IL과 같이 최소 부상 기간을 뜻하나 투수에게만 적용된다는 차이점이 있다. 마지막으로, 60-day IL은 팔꿈치 내측 인대

부상, 십자인대 파열 등과 같이 장기간의 재활이 요구되는 심각한 부상 분류를 뜻한다. 한국 선수 중에는 토론토 블루제이스 류현진 선수가 팔꿈치 내측 인대 수술을 받은 후 2022년 6월 28일부터 60일 부상자 명단으로 이동되었다. 그 외에도 2020년부터는 코로나 19로 인해 COVID-19 Related IL도 포함이 되었으나, 본 연구와의 관련성이 떨어지기 때문에 데이터 전처리 과정에서 제외하고자 한다.

IL에 등재되면 해당 기간 경기 출장이 불가하고, 당해 시즌이 종료되면 모든 부상자는 명단에서 해제되며, 다음 해 스프링캠프 때부터 IL에 다시 등재될 수 있다. <표 2>를 통해 IL 종류별로 적용되는 제도를 확인할 수 있으며, IL을 더 알기 위해서는 ‘소급적용’, ‘재활 경기’, ‘서비스 타임’에 대한 추가 이해가 필요하다.

구분	26인 로스터	40인 로스터	소급적용	재활 경기	서비스 타임
7일 부상자 명단 (7-day IL)	제외	유지	가능	가능	유지
10일 부상자 명단 (10-day IL)	제외	유지	가능	가능	유지
15일 부상자 명단 (15-day IL)	제외	유지	가능	가능	유지
60일 부상자 명단 (60-day IL)	제외	제외	가능	가능	유지

표 2 부상자 명단 종류별 주요 적용 제도

먼저, 소급적용 제도는 선수가 마지막 게임 출전한 날로부터 소급되는 것을 말한다. 예를 들어 5월 12일에 뇌진탕 진단을 받았다면 5월 12일부터 ‘7일 부상자 명

단'에 등재되어야 하는데, 만약 5월 9일에 마지막 경기를 치른 경우라면 5월 10일부터 소급 적용되어 5월 17일에 IL에서 해제될 수 있다.

다음, 재활 경기(Rehab assignment) 제도는 IL 해제 후 바로 메이저리그에 바로 복귀하지 않고, 마이너리그에서 실전 감각을 되찾고 체력을 회복할 수 있도록 돕는 기간을 말하며, 타자는 최대 20일, 투수는 최대 30일의 재활 경기를 치른 후 복귀할 수 있다.

마지막으로, 서비스 타임 제도는 부상으로 인해 경기를 참가하지 못하게 되더라도 그 기간을 선수 활동 기간으로 인정해 주는 제도를 말한다. MLB는 선수들의 경력을 '서비스 타임'으로 관리하는데, 선수들에게는 경력 관리와 권리 행사에 중요한 지표이기 때문에 매우 중요하다. 서비스 타임 제도에서 연차별 권리를 살펴보면, 3년 미만은 경우, 선수의 연봉은 구단에 의해 결정되지만, 3년 이상이 된 선수는 연봉조정을 신청할 수 있다. 또한 5년을 넘긴 선수는 마이너리그로의 이동을 거부할 수 있는 권리를 가지며, 6년을 채운 선수는 FA시장에 진출할 권리를 가지게 된다.

4. 딥러닝(Deep Learning, DL)

1) 딥러닝의 개념과 원리

Yann LeCun et al. (2015)에 따르면, 딥러닝은 사람의 직접적인 엔지니어링을 거의 요구하지 않고, 방대한 데이터도 쉽게 활용할 수 있어 앞으로 더 주목받는 기술이 될 것이라고 주장하였다. 딥러닝(Deep Learning)은 인공 신경망(Artificial Neural Networks, ANN)의 한 형태로, 매우 크고 복잡한 데이터셋을 모델링할 수 있는 기계학습(Machine Learning, ML)의 방법론 중 하나이다.

딥러닝은 몇 가지 주요 구성 요소로 이루어져 있는데, 이러한 구성 요소 중 하

나는 레이어(Layer)와 노드(Node)이다. 레이어는 여러 노드로 구성되어 있으며, 각 노드는 데이터를 입력받아 목표 변수와의 관계를 찾기 위한 여러 특성들을 학습한다. 또한, 딥러닝 모델에는 일반적으로 여러 개의 은닉 레이어가 포함되어 있으며, 각 레이어는 다음 레이어로 전달하기 전에 더 복잡한 특성을 추출하고 변형한다.

딥러닝의 또 다른 핵심 요소는 역전파(Backpropagation)라는 학습 메커니즘이다. 이 메커니즘은 모델의 오차를 최소화하는 데 사용되는 가중치를 업데이트하는 역할을 하는데, 역전파는 모델의 출력과 실제 목표값 간의 오차를 계산하고, 이 오차를 역방향으로 전파하여 각 레이어의 가중치를 조정한다. 이 과정에서 경사 하강법(Gradient Descent)과 같은 최적화 알고리즘을 사용하여 각 레이어의 가중치를 조정함으로써 모델의 출력값이 실제값과 가까워지도록 학습하는 것이다.

2) 딥러닝의 활용 분야 및 장단점

딥러닝 기술은 이미지 분류, 음성 인식, 자연어 처리에서 강점을 가지며, 의료 산업, 사이버 보안, 공급망 관리 등에서 활용되고 있다.

특히 딥러닝의 큰 장점 중 하나는, 사람이 직접 데이터의 특성을 공학적으로 설계하는 전통적인 기계학습 접근법과 달리, 모델이 데이터로부터 복잡한 패턴을 직접 학습하고, 이를 이용해 예측이나 분류 작업을 수행한다는 것이다. 이처럼, 딥러닝은 인공 신경망을 사용하여 복잡한 표현을 학습하면서, 이전에 확인할 수 없었던 데이터에 숨겨진 특성까지 발견할 수 있는 강력한 기계학습 방법이다.

딥러닝에는 단점도 있다. 대표적으로는 크고 복잡한 모델의 훈련에는 대량의 데이터와 컴퓨팅 자원이 필요하다는 점이다. 또한 딥러닝 모델은 ‘블랙박스’로 불리기도 하는데 이는 모델 내부의 복잡한 연산 과정이 인간이 이해하기 어려워 해석하기 어렵다는 점을 뜻한다. 이는 특히 중요한 의사결정에 딥러닝을 적용할 때 문제가 될 수 있다.

또한 딥러닝 모델은 과적합(Overfitting)에 취약하다. 모델이 학습 데이터에 너무 정확하게 적합되어 새로운 데이터에 대한 예측력이 떨어지는 현상을 의미하는데, 이는 특히 복잡한 모델에서 흔히 발생하는 문제이다. 이러한 과적합을 방지하거나 완화하기 위해 여러 규제화(Regularization) 방법들이 사용되며, 학습률(Learning rate) 조절이나 드롭아웃(Dropout)과 같은 기법들이 학습 초기 단계에서 적용될 수 있다.

딥러닝은 본 연구를 풀어갈 핵심기술로, 그 성능과 다양성으로 인해 많은 연구자와 개발자들에게 선택받는 중요한 도구이다. 딥러닝 기술의 빠른 발전으로 인해 많은 실제 응용 분야에서 뛰어난 결과를 내고 있으며, 현대 인공지능의 성공을 주도하는 중요한 역할을 하고 있다. 이러한 이유로 딥러닝은 계속해서 연구와 개발의 중심에 서 있으며, 앞으로도 그 중요성이 증가할 것으로 예상된다.

3) 지도학습: 이진분류(Binary Classification)

지도학습(Supervised Learning)은 가장 널리 사용되는 기계학습 방법의 하나로, 모델이 입력 데이터(X)와 관련된 출력값(Y)의 쌍을 학습하여, 새로운 입력 데이터가 주어졌을 때 해당 출력값을 예측하는 방법론이다. 다시 말해, 모델은 기존의 입력-출력 쌍을 이용하여 학습하며, 이 학습을 통해 테스트 데이터에 대한 출력값을 예측하게 된다. Shah, D et al. (2022)는 지도학습이 각각의 데이터셋에 출력값을 제공하는 구조화된 데이터셋으로 구성되기 때문에, 모델이 학습할 때 매우 효율적으로 작동한다고 하였다. 이처럼, 지도학습의 효과성은 많은 연구에서 입증되었으며, 특히 복잡한 패턴이나 상관관계를 파악해야 하는 문제에서 강력한 성능을 발휘한다.

지도학습은 분류(Classification) 또는 회귀(Regression)라는 두 가지 주요 작업으로 분류되는데, 본 연구에서는 분류 문제 중에서도 이진 분류(Binary Classification)

로 접근할 예정이다. <그림 2>에서 확인할 수 있듯이, 이진 분류는 주어진 입력을 클래스 A 또는 B 중 하나로 분류하는 것을 뜻하는데, 사진 속 동물이 ‘강아지인지 고양이인지를 분류하거나’, 이메일이 ‘스팸인지 아닌지를 분류하거나’, 환자가 ‘특정 질병에 걸렸는지 걸리지 않았는지’를 예측하는 것이 이진 분류 문제의 예이다.




그림 2 Binary Classification with Decision Boundary

딥러닝 모델을 이용한 이진 분류는 다음과 같은 과정을 거친다. 먼저, 학습 데이터셋을 이용하여 딥러닝 모델을 학습시킨다. 각 입력 데이터는 레이블이라는 출력 값과 연결되어 있으며, 이 레이블은 해당 데이터가 두 범주 중 어디에 속하는지를 나타낸다. 딥러닝 모델은 이 학습 데이터셋을 이용하여, 입력과 레이블 사이의 복잡한 패턴을 학습하게 된다. 모델이 학습되면, 새로운 입력 데이터에 대해 이를 두 범주 중 하나로 분류할 수 있는데, 모델은 학습 과정에서 배운 패턴을 이용하여, 새로

운 입력이 어느 범주에 속하는지를 예측하게 된다. 이 예측값은 그 후 실제 레이블과 비교되어, 모델의 성능을 평가하는 데 사용된다.

4) 데이터 불균형 문제와 샘플링 전략

데이터 불균형은 분류를 목표로 하는 기계학습 문제에서 클래스 레이블의 분포가 균등하지 않은 상태를 의미하는데, 이러한 불균형 상태는 모델의 학습과 성능에 큰 영향을 미칠 수 있다. 이 문제는 실제 많은 상황에서 발생하는데, 본 논문의 주제인 부상 예측 연구도, 부상이 없는 경우의 데이터가 부상이 있는 경우의 데이터보다 훨씬 많다. 이런 문제를 해결하지 않고 학습을 진행하게 되면, 모델은 다수 클래스의 패턴 중심으로 학습하게 되어 소수 클래스의 패턴을 무시하거나 오해하는 경향이 생길 수 있다. 따라서, 데이터 불균형이 있는 상황에서는 ‘정확도’가 높게 나타나더라도, ‘정밀도’, ‘재현율’, ‘F1 점수’ 등과 같은 다른 평가 지표에서 좋지 않은 성능이 나올 수 있다(Mohammed, R et al., 2020).

He, H., & Garcia, E. A. (2009)은 데이터 불균형 문제를 해결하기 위해 일반적으로 샘플링 방법을 사용하여 균형 있는 데이터셋을 만든다고 하였다. 또한, 불균형한 데이터셋에 비해 균형 잡힌 데이터셋의 성능이 전반적으로 더 좋다는 사실은 이미 많은 연구를 통해 증명되었다고 덧붙였다.

불균형 문제를 해결하기 위한 방법은 다양한데, 가장 기본적인 방법은 오버샘플링(Oversampling)과 언더샘플링(Undersampling)이다. 오버샘플링은 소수 클래스의 샘플을 복제하거나 합성하여 샘플 수를 늘리는 방법이고, 언더샘플링은 다수 클래스의 샘플을 제거하여 두 클래스 간의 샘플 수를 균형 있게 맞추는 방법이다.

데이터 불균형 문제는 본 연구인 MLB 투수 부상 예측 모델 개발에 중요한 고려 사항이다. 특히, 심각한 불균형이 존재하는 경우 이를 무시하게 되면 모델의 성

능에 큰 영향을 미칠 수 있다는 점을 명심해야 한다. 이에, 문제의 특성, 사용하는 모델, 데이터의 특성 등을 고려하여 여러 샘플링 전략 중 가장 적절한 방법을 찾고 적용하는 과정을 깊이 있게 수행할 예정이다.

5. 차원 축소 기법(Dimensionality Reduction)

차원 축소 기법은 고차원 데이터의 차원을 줄이고 시각화함으로써, 분석을 효과적으로 수행하는데 사용되는 기술로, 대표적인 예로는 주성분 분석(PCA)과 t-SNE(t-Distributed Stochastic Neighbor Embedding)가 있다.

먼저, PCA는 정보 손실은 최소화하면서도 차원 축소를 통해, 점점 더 방대해지고 해석하기 어려운 고차원 데이터의 해석 가능성을 높이는 기술이라고 할 수 있다(Jolliffe, I. T., & Cadima, J., 2016). PCA는 데이터의 분산을 최대한 보존하는 새로운 축을 찾는 선형적인 방법을 사용하여 고차원의 데이터를 저차원으로 축소한다. 하지만 이 방식은 비선형 구조를 놓칠 수 있다. 이에 반해, t-SNE는 고차원 공간에서 가까이 있는 점들이 저차원 공간에서도 가까이 있도록 데이터를 재배치하는 비선형적인 차원 축소 기법을 사용한다(Kracker, D et al., 2020).

PCA와 t-SNE는 본질적으로 데이터의 차원을 축소하는 데 목적을 두지만, 각각이 갖는 특징과 제약사항으로 인해 적절한 상황에서 선택하여 사용해야 한다. 다시 말해, PCA는 선형적인 구조를 갖는 데이터에 대해서는 뛰어난 성능을 보이지만, 비선형적인 구조를 갖는 데이터에 대해서는 t-SNE가 더 적합할 수 있다.

본 연구에서는 투수의 부상 가능성을 예측하는 모델 개발이 목적이기 때문에, 모델링 전에 PCA와 t-SNE를 활용하여 부상과 비부상 간의 고차원 데이터를 저차원으로 축소한 후, 투수의 부상 예측 모델 개발의 가능성을 확인해 보고자 한다.

6. 커널 밀도 추정(Kernel Density Estimation, KDE)

커널 밀도 추정(Kernel Density Estimation, KDE)은 확률 밀도 함수(PDF)를 추정하는 기법으로, 기존 히스토그램보다 더욱 세밀한 확률분포 분석을 가능하게 한다. 이 방법은 곡선의 굴곡을 보다 잘 표현하고, 데이터에 포함된 정보를 더욱 명확하게 나타낼 수 있다(Węglarczyk, S., 2018). 또한, KDE는 이상치나 특이치를 찾아내는 데도 유용하여 다양한 데이터 분석 기법의 핵심 구성 요소로 사용되고 있다.

KDE는 각 데이터 포인트에서 커널 함수를 중심으로 설정하고, 이들을 합쳐서 연속적인 밀도 추정치를 생성한다. 주로 사용되는 커널 함수로는 가우시안, Epanechnikov 등이 있다.

각 커널 함수는 특정 폭(bandwidth)을 가지며, 이 폭은 밀도 추정의 세부적인 형태를 결정한다. 이 폭의 선택은 중요한 문제로, 너무 작은 폭은 데이터의 과도한 변동성을 반영하는 Undersmoothing 현상을 초래할 수 있고, 반대로 너무 큰 폭은 데이터 간의 차이점을 과소평가하는 Oversmoothing을 초래할 수 있다. 폭의 선택에 대한 다양한 방법론이 제안되었으며, 그중 하나로 여러 커브를 그려보고 각각의 결과를 평가하여 최적의 폭을 선택하는 Trial-error(시행착오법)가 있다(남준우, 2000).

본 연구에서는 MLB 투수 부상 예측 모델을 구축하기 전, KDE를 통해 스탯캐스트 및 부상 데이터의 복잡한 분포를 이해하는 과정을 수행하고자 한다.

7. 선행연구

투수 부상과 관련된 선행연구를 살펴보면, 스포츠안전재단(Korea Sports Safety Foundation, 2019)에서는 야구(소프트볼 포함) 종목에서 생활체육인, 전문체육인의

주요 부상 부위로 1위 팔꿈치, 2위 어깨 순으로 나타났다고 하였다.

Erickson, B. J et al. (2016)은 야수들은 하지에 부상을 입을 가능성이 높지만, 투수들은 상지에 부상을 입을 가능성이 높다고 하였다. 특히, MLB 전체 투수 중 25%~33%가 팔꿈치 내측 인대 재건술(UCLR)을 받았으며, 그 숫자가 많이 증가하고 있다고 말했다.

Hibberd, E. E. et al. (2015)는 투수들은 회전근개 손상, 어깨 불안정성 등의 상체 부상으로 인해 큰 손실을 겪는다고 하였다. 특히, MLB에서 부상자 명단에 등재되는 선수 중 절반가량이 투수인데, 이들 중 약 67%가 상체에 부상을 입으며, 그중에서도 어깨와 팔꿈치 부상이 빈번하다고 보고하였다.

변경석 (2019)은 투구 유형과 관계없이 투구의 릴리스 전후 지점에서 팔꿈치 관절에 높은 부하가 발생한다고 하였다. 더불어, 상완의 최대 외회전 시점 전후와 릴리스 시점에서 어깨 관절에 높은 부하로 인해 어깨 관절 손상을 입힐 가능성이 있다는 점을 강조하였다.

Olsen, S. J et al. (2006)는 청소년 투수를 대상으로 어깨와 팔꿈치 부상에 영향을 미치는 요인들에 대해 분석했는데, 투수들이 과도한 투구를 하거나 빠른 공을 많이 던질 때 부상 위험이 커진다고 하였다.

Eric C. Makhni et al. (2014)는 팔꿈치 내측 인대(UCL) 수술을 받은 선수들의 약 80%가 MLB에 복귀하였지만, 이들 대다수는 수술 전보다 수술 후의 경기력이 감소하는 경향을 보였다고 하였다.

마지막으로, Drew Bennison, Mallet James (2021)는 2015시즌~2020시즌의 스탯캐스트와 XGBoost Classifier 모델을 활용하여 선발 투수의 상체 부상 예측 연구를 수행하였다. 결과적으로 'Season pitch count, release speed FF, game pitch count' 순으로 상체 부상 예측에 중요한 특징을 확인할 수 있었고, 경기 날짜로부터 2주 이내에 선발 투수가 부상을 당할지에 대한 여부를 분류할 수 있었다고 하였다.

선행연구를 종합하면, 투수의 상체 부상, 특히 팔꿈치와 팔, 어깨 부상이 주요 문제로 지적되고 있으며, 이는 투구 유형, 팔의 회전 및 부하 등과 밀접한 관련이 있다는 것을 보여주고 있다. 또한 기계학습 방법론을 활용하여 투수 부상 예측을 시도한 Drew Bennison, Mallet James (2021)의 연구를 통해 이와 같은 접근법이 효과적일 수 있음을 확인할 수 있었다.

이에 본 연구 방향을 재정리해 보면, 투수들에게 위협이 되는 어깨와 팔, 그리고 팔꿈치 내측 인대 부상과 같은 주요 상체 부상을 중심으로, 투수들의 부상을 예방하는 데에 기여할 수 있는 예측 모델을 개발하고자 한다. 이를 통해, 이전에는 발견하지 못했던 부상 전 투구의 특정 패턴이나 주요 특성을 찾아내어 부상 신호를 더욱 정확하게 예측하고, 투수들이 더욱 안전하게 경기를 이어갈 수 있도록 지원하는 것이 본 연구의 목표다. 이러한 접근은 투수들의 부상 예방과 빠른 회복에 실질적인 도움을 제공하고, 스포츠 상황에서의 딥러닝 기술을 활용한 부상 예측 연구 가능성이 대한 이해를 더욱 깊게 할 수 있을 것이다.

제3장 데이터 분석 및 전처리

1. 데이터 수집

본 연구는 Statcast 데이터가 안정적으로 활용되기 시작한 2017시즌부터 2022시즌까지 활동한 선발투수(Starting Pitcher)뿐만 아니라 구원투수(Relief Pitcher), 마무리투수(Closer)까지 모든 MLB 투수를 대상으로 한다.

투구데이터 수집은 베이스볼 서번트(Baseball Savant)에서 제공하는 ‘Statcast Search’ 페이지에서 실시하였으며(<그림 3> 참조), ‘Group By’ 기능을 이용하여 선수별 연간 및 월간 투구 데이터(‘Player & Year’, ‘Player & Month’) 등의 기본 자료를 수집하였다.

Statcast Search
An application that lets you search MLB.com's Statcast database. It includes metrics such as Perceived Velocity (PV), Spin Rate (SR), Exit Velocity (EV), Hit Distance (DST), Launch Angle (LA), Batted Ball Direction (BBD), xBA, xSLG, xwOBA, and Quality of Contact.

- Some of these queries are very complicated and take time to run. If the page doesn't fully load, refresh the page and try again.
- Pitch velocities from 2008-16 are via Pitch F/X, and adjusted to roughly out-of-hand release point. All velocities from 2017 and beyond are Statcast, which are reported out-of-hand.
- For the limited subset of batted balls not tracked directly, estimates are included based on the process described [here](#).
- For CSV documentation click [here](#).
- For a detailed tutorial on using the search click [here](#).

Pitch Type:		PA Result:		Season Type:	Regular Season
Pitch Result:		Gameday Zones:		Venue:	
Batted Ball Location:		Attack Zones:		Batted Ball Direction:	
Count:		Season:	2023	Situation:	
Player Type:	Pitcher	Outs:		Opponent:	
Pitcher Handedness:		Batter Handedness:		Quality of Contact:	
Game Date >=		Game Date <=		Month:	
Team:		Home or Away:		Runners On:	
Position:		IF Alignment:		OF Alignment:	
Inning:		Batted Ball Type:		Batters:	Enter Player Name...
Flags:				Pitchers:	Enter Player Name...
Metric Range:					
Group By:	Player Name	Min # of Total Pitches:	None	Min # of Results:	None
Min PA:	None	Sort By:	Pitches	Sort Order:	Desc

[Search](#) [Change Included Stats](#) [Change Total Pitch Parameters](#) [Clear Search](#)

그림 3 베이스볼 서번트 스탯캐스트 data 제공 서비스

다만, 한 시즌의 원자료(Raw data) 용량이 300~400MB에 달하다 보니, 'Statcast Search' 페이지 내에서 6개 시즌의 데이터를 직접 추출하는 것은 어려웠다. 이에, 파이썬(Python)에서 야구 데이터 분석 패키지인 'pybaseball'을 활용하여, 2017시즌~2022시즌 MLB 시즌의 Statcast 데이터를 수집하였다. 데이터 특징은 인덱스(Index)를 포함하여 총 4,040,650개의 행(Row)과 92개의 컬럼(Columns), 데이터 타입(dtypes)은 47개의 실수형(float64), 28개의 정수형(int64), 17개의 객체형(object)으로 구성되어 있었으며, 전체 데이터 크기는 약 2.8GB였다.

부상데이터 수집은 스포트랙(Spotrac)에서 제공하는 'MLB Injured List Tracker' 페이지에서 실시하였다. 해당 페이지는 모든 선수의 부상 정보를 '연도', '현재 또는 누적 정보', '소속팀', '포지션'별로 선택하여 탐색할 수 있는 기능을 제공한다. 수집 방법은, 웹 스크래핑(Web Scraping) 기능을 사용하여 2017시즌부터 2022시즌까지의 MLB 투수 부상 정보를 얻었으며, 기초적인 데이터 전처리 후 전체 2,136행, 8열, 총 1,050명의 부상 경험 투수의 정보가 담긴 데이터프레임을 만들었다.

스포트랙에서 제공하는 부상 정보는 선수 이름(PLAYER), IL 등재 시 부상 부위(INJURY), IL 등재 시 부상 정도에 따른 분류(STATUS), IL 등재 기간(DATES) 등의 데이터를 포함하고 있다(<그림 4> 참조).

PLAYER (169)	POS.	TEAM	INJURY	STATUS	DATES	DAYS	CASH EARNED WHILE ON IL
Taylor Megill		NYM	Covid 19/Shoulder/Biceps	15-day	10/5 - 10/5 6/17 - 9/19 5/12 - 6/11	127	\$491,076
Mike Clevinger		SD	Covid 19/Arm/Knee	15-day	10/5 - 10/5 6/11 - 6/17 5/22 - 6/5 4/4 - 5/4	54	\$1,893,228
Carlos Rodon		SF	Covid 19	10-day	10/4 - 10/5	2	\$236,264
Edward Cabrera		MIA	Ankle/Elbow	15-day	10/3 - 10/5 6/15 - 8/4	54	\$207,684
Logan Webb		SF	Back	15-day	10/2 - 10/5	4	\$16,044
Michael Grove		LAD	Knee	15-day	10/2 - 10/5	4	\$15,384

그림 4 스포트랙의 MLB 선수 부상자 명단 제공 서비스

일반적으로, 스포츠에서의 부상은 발생 원인에 따라 급성 부상과 만성 부상으로 분류된다. 급성 부상은 경쟁적인 스포츠 활동 중 격렬한 접촉이나 충돌에 의해 발생하는 손상을 뜻하고, 만성 부상은 오랜 기간 동안 반복적 움직임에 의해 발생한 미세한 손상이, 자체적인 회복 능력을 초과하게 되면서 정상적인 조직에 손상을 주는 상태를 가리킨다(박재용, 2016).

부상 발생 원인을 파악하는 것은 치료 방법, 예방 전략, 그리고 부상 회복 과정에 중대한 영향을 미치므로, 부상 치료와 재활 연구에서는 필수적인 요소이다. 하지만, 스포트랙에서는 부상 발생 원인까지는 정보로 제공하지 않기 때문에 모든 부상에 대한 원인을 파악하는데는 어려움이 있다. 이러한 한계를 고려하여, 본 연구에서는 부상 발생 원인은 제외하고, ‘어깨(Shoulder)’, ‘팔(Arm)’과 같이 부상 부위까지만 분류하여 투수 부상 예측 모델 개발에 활용하고자 한다.

2. 데이터 탐색

1) 스탯캐스트 데이터

Statcast 데이터는 투구 하나당 1개의 행(row)에 92개 컬럼(Columns)을 담고 있는데, 이 중 타자 요인, 수비 요인, 추적 시스템 변경 후 사용하지 않는 요인, 게임 스코어 요인 등 투수 부상과 연관성이 떨어지는 요인은 모두 제거하고, 투수와 관련된 요인만 <표 3>와 같이 정리하였다.

대표적인 요인으로는 구종 유형(pitch type), 구종별 속도(release speed), 포수의 관점에서 관측된 바닥으로부터의 공의 좌우 위아래 릴리스 포인트 위치(release pos x, release pos z), 포수의 관점에서 플레이트를 지난 공의 좌우 위아래 위치(plate x, plate z), y=50 피트에서 결정된 x, y, z 좌표상의 공의 속도·가속도(vx0, vy0,

vz0, ax, ay, az), 투구 회전율(release spin rate) 등이 있다.

요인	정의
pitch type	구종 유형
game date	경기일자
release speed	구종별 속도
release pos x	포수 관점에서 관측된 바닥으로부터 볼의 수평 릴리스 포인트 위치
release pos y	포수 관점에서 관측된 플레이트까지 직선거리
release pos z	포수 관점에서 관측된 바닥으로부터 볼의 수직 릴리스 포인트 위치
player name	선수명
pitcher	투수 id
events	타석 결과
description	투구 결과 정보
zone	포수 관점에서 플레이트를 지난 볼의 스트라이크 존 위치
game type	경기별 타입
p throws	좌투수/우투수 정보
home team	홈 팀 이름
away team	어웨이 팀 이름
type	투구 결과 정보
balls	(투구 직전)의 볼 카운트 개수
strikes	(투구 직전)의 스트라이크 카운트 개수
game year	경기년도
pfx x	포수 관점에서 바닥으로부터의 공의 수평 무브먼트
pfx z	포수 관점에서 바닥으로부터의 공의 수직 무브먼트
plate x	포수 관점에서 플레이트를 지난 공의 수평 위치
plate z	포수 관점에서 플레이트를 지난 공의 수직 위치
outs when up	(투구 직전)의 아웃카운트 개수
inning	(투구 직전)의 이닝수
inning topbot	이닝의 초(top), 말(bot) 정보
vx0, vy0, vz0	y=50 피트에서 결정된 x, y, z 좌표상 투구의 초속
ax, ay, az	y=50 피트에서 결정된 x, y, z 좌표상 투구의 가속도
effective speed	투수의 익스텐션 시의 유효속도
release spin rate	투구 회전율
release extension	투구 익스텐션 거리
at bat number	(해당경기에서) 타석 번호
pitch number	(해당타석에서) 총 투구 수
pitch name	구종 이름
spin axis	2D X-Z 평면의 스핀 축은 0에서 360 사이의 각도

표 3 연구에 사용할 Statcast 데이터 요인

먼저, <그림 5>와 같이 투수의 평균 경기 출전 횟수(Avg Games Played)와 투구 수(Avg Pitch Count) 분포를 확인해 보았다. 코로나로 인한 2020시즌을 제외하고 선수당 한 해 평균 출전 수는 20회 이상, 선수당 한 경기별 평균 투구 수는 34회 이상 수준으로 나타났으며, 두 지표 모두 2017시즌부터 감소하는 경향을 보였다.




그림 5 연도별 평균 출전 횟수 및 경기별 평균 투구 수

Karakolis, T et al. (2013)의 연구에 따르면, MLB 투수들의 누적 투구량과 부상 발생 간의 상관관계를 분석하였는데, 몇 가지 흥미로운 추세는 발견되었지만, 누적 투구량이 부상 예측에 중요한 변수로 작용하지 않았다고 하였다. 그러나 이런 선행 연구는 부상과의 상관관계를 단일 변수만으로 분석했다는 한계점이 있고, 누적 투구량과 부상 발생 연관성에 대한 이슈가 여전히 존재한다는 점을 고려할 때, 본 연

구에서 이러한 변수를 다양한 변수들과의 관계 속에서 종합적으로 검토할 필요가 있다.

다음으로는 피어슨 상관계수를 사용하여, 변수 간 어떤 관계를 맺고 있는지 분석하였다. 피어슨 상관계수는 선형 관계를 중심으로 평가하기 때문에 비선형 관계를 간과할 수 있다는 문제점을 지니고 있지만, 초기 탐색 단계에서는 변수 간의 기본적인 관계를 이해하는 데 유용하게 사용될 수 있다. 이에, 투수 부상과의 관련성이 크게 나타난 변수(투수가 공을 던질 때의 속도(release speed), 공이 투수의 손을 떠나면서 얻는 y축 방향의 초기 속도(vy0), 공이 투수의 손을 떠날 때의 회전 속도(release spin rate), 투수가 공을 던지는 지점의 높이(release pos z))의 분포를 <그림 6>과 같이 확인할 수 있었다.




그림 6 연도별 평균 release speed, vy0, release spin rate, release pos z

또한, 위 4가지 변수의 평균을 구하였는데, 각각의 평균은 88.78mph, -129.05ft/s, 2239.02RPM, 5.86ft였다. release speed와 vy0는 코로나 발생 시즌인 2020시즌에 큰 폭락으로 떨어졌다가 2021시즌에는 급격하게 상승하는 양상을 보였고, release spin rate는 2017시즌부터 2022시즌까지 점진적으로 증가하는 경향을, release pos z는 2017시즌 2022시즌 점진적으로 소폭 감소하는 형태를 보였다.

마지막으로 구종(pitch type)에 대한 분석을 실시하였는데, 사용 구종 빈도순으로 4-Seam Fastball이 1,380,960회로 전체 구종의 약 35.1%를 차지하였고, Slider가 691,247회로 약 17.6%, Sinker가 690,076회로 약 17.5%, Changeup이 427,528회로 약 10.8%, Curveball이 325,768회로 약 8.2% 비율로 사용되는 것으로 확인되었다.

2) 부상데이터

2017시즌부터 2022시즌까지 연간 평균 부상 발생 횟수는 약 418건이었으며, 연도별로는, 2017시즌에 359건, 2018시즌에 426건, 2019시즌에 394건으로 나타났다. 2020시즌에는 267건으로 부상 발생이 감소하였지만, 2021시즌에 571건, 2022시즌에 490건으로 부상 발생 횟수가 눈에 띄게 증가하는 모습을 보였다.

II. 등재 월별 빈도를 살펴보면, 4월에 가장 많은 부상이 발생하였고, 5월부터 8월까지는 부상자 수가 계속해서 증가하는 추세를 보였다(<그림 7> 참조). 4월 부상이 많은 이유로는, 시즌 시작 후 갑작스러운 신체 사용과, 11월부터 2월까지 경기가 없는 오프시즌 동안 훈련 등으로 발생한 부상을, 시즌 시작 시기인 3~4월에 공식적으로 등재하는 경우가 있어 4월에 부상 빈도가 높은 것으로 추정된다.

‘특정 연도나 월에 부상이 더 자주 발생하는지’, ‘부상 발생률이 증가 또는 감소하는지’ 등의 추세를 파악하는 것은, 과거 데이터를 기반으로 미래의 부상 위험을 예측하는 데 중요한 참고 자료가 될 수 있다. 또한 기계학습 결과 외에도 투수의 부상 예방을 위한 직관적인 인사이트를 줄 수 있으므로 신중한 분석이 필요하다.




그림 7 2017시즌~2022시즌 부상자명단 등재 월별 분포

스포츠랙에서 분류하고 있는 39가지의 모든 부상 종류를 <표 4>와 같이, ‘상체, 하체, 질병 및 그 외 부상’으로 그룹화하고 분류하였다. 복부, 팔, 허리와 같은 ‘상체 부상’ 16가지, 아킬레스, 발목, 종아리와 같은 ‘하체부상’ 16가지, 상체·하체 부상이 아닌 심장(Heart)과 같은 부상 7가지는 ‘질병 및 그 외 부상’으로 분류하였다.

실제로 투수는 과도한 피칭으로 어깨 및 팔꿈치에 부상을 입을 수도 있고, 타자가 친 공에 머리를 맞아 뇌진탕을 입을 수 있고, 수비를 하다가 발목 염좌가 발생할 수도 있으며, 경기 외적으로 일상생활에서 심혈관계 질환이나 코로나와 같은 질병에 걸릴 수도 있다. 이처럼, 투수는 다양한 이유로 부상을 당할 수 있는데, 모든 부상을 예측에 활용하는 것보다 특정 부상을 집중적으로 연구하는 것이 예측 모델의 성능 개선이나 현장 활용 측면에서 더 의미가 있을 수 있다. 이에 본 연구에 적절한 특정 부상을 더 살펴보고자 하였다.

분류	부상 종류
상체부상 (16)	Abdominal(복부), Arm(팔), Back(허리), Biceps(이두근), Elbow(팔꿈치), Elbow Tommy John(팔꿈치 내측 인대), Finger(손가락), Hand(손), Neck(목), Oblique(복사근), Pectoral(가슴), Ribs(갈비뼈), Shoulder(어깨), Thumb(엄지손가락), Ulnar Nerve(척골신경), Wrist(손목)
하체부상 (16)	Achilles(아킬레스), Ankle(발목), Calf(종아리), Glute(둔근), Groin(사타구니), Hamstring(햄스트링), Heel(뒤꿈치), Hip(엉덩이), Knee(무릎), Knee MCL(무릎 내측측부인대 손상), Knee ACL(무릎 전방십자인대 손상), Leg(다리), Quad(대퇴사두근), Shin(정강이), Thigh(허벅지), Toe(발가락)
질병 및 그 외 부상 (7)	Concussion(뇌진탕), Head(머리), Heart(심장), Illness(질병), Nose(코), Stomach(위), Undisclosed(미상)

표 4 부상 종류 분류 (스포츠랙 기준)

먼저 Drew Bennison, Mallet James (2021) 연구에서는, 상체 부상은 실제 투구 행위에 의해 발생할 가능성이 더 높기 때문에, 투구데이터를 활용한 부상 예측 연구 시에는 부상 범위를 상체 부상만 활용하는 것이 유용하다고 하였고, 그 외 Hibberd, E. E et al. (2015)와 Erickson, B. J et al. (2016) 등의 선행연구에서도 어깨나 팔꿈치, 팔꿈치 내측 인대 등과 같은 상체 부상을 주요 문제로 언급하였다.

본 연구가 투구 행위로 인한 구질의 미세한 특성 변화를 파악하여 부상을 감지할 수 있는 예측 모델 개발이 주목적인 점을 고려할 때, 본 연구에서 다룰 부상 종류 범위를 ‘상체 중심의 부상’으로 한정하는 것이 적절할 것으로 보인다. 하지만, 16가지의 상체 부상을 모두 다룰 시, 예측 모델의 복잡성이 여전히 커서 성능 저하가 있을 수 있고, 무엇보다 연구 결과를 현장에 적용할 시, 예측한 부상의 종류가 광범

위하여 결과 해석에 혼란이 있을 수 있다. 따라서 투수에게 자주 발생하는 부상이나, 부상 발생 시 큰 위협이 되는 부상 중심으로 부상 연구 범위를 더 축소할 필요가 있었다. 이에, <그림 8>과 같이 부상 부위별 발생 빈도수를 조사해 보았는데, Shoulder(어깨) 525건, Elbow(팔꿈치) 355건, Arm(팔) 286건, Back(허리) 204건, Elbow Tommy John(팔꿈치 내측 인대) 121건 순으로 부상이 발생한 것을 확인할 수 있었다.




그림 8 2017시즌~2022시즌 부상자 명단에 등재된 부상 종류별 집계

또한 부상의 심각성은 부상 후 경기 복귀까지의 소요된 기간으로 볼 수 있는데, 부상 발생 빈도가 높은 부상의 평균 회복 기간을 살펴보면 Elbow Tommy John(팔꿈치 내측 인대) 134.9일, Elbow(팔꿈치) 69.3일, Arm(팔) 57.7일, Shoulder(어깨) 50.9일, Back(허리) 36.3일의 회복 기간을 요구하는 것을 확인할 수 있었다.

부상 종류별 발생 빈도와 부상으로 인한 회복 기간은 부상의 위험도를 평가하는

주요 지표가 될 수 있다. 이에, 각 부상 유형의 발생 빈도 F 와 부상으로 인한 평균 회복 기간 D 의 곱으로, 투수 부상에 대한 위험도 R 을 정의하였다(<수식 1> 참조). 여기서 i 는 특정 부상 종류로 부상위험도 R_i (Injury Risk)은 특정 부상이 투수나 구단에 얼마나 큰 위협을 주는지를 나타내는 종합적인 지표로 이해할 수 있다.

$$R_i = F_i \times D_i$$

수식 1 Injury Risk

이를 바탕으로 <표 5>과 같이 부상위험도가 큰 순서대로 1위부터 10위까지 나열해 보았는데, Shoulder(어깨), Arm(팔), Elbow(팔꿈치), Elbow Tommy John(팔꿈치 내측 인대) 부상의 부상위험도가 16,000 건·일 이상인 것으로 나타났다. 즉, 해당 부상들은 투수 개인과 구단에 가장 위협이 되는 부상으로 해석할 수 있으므로, 이 4가지 부상을 바탕으로 예측 연구를 수행하는 것이 유용할 것으로 판단되었다.

No.	부상 종류	발생 빈도(건)	회복 기간(일)	부상위험도(건·일)
1	Shoulder	525	50.9	26,722.5
2	Elbow	355	69.3	24,601.5
3	Arm	286	57.7	16,502.2
4	Elbow Tommy John	121	134.9	16,322.9
5	Back	204	36.3	7,405.2
6	Oblique	118	40.2	4,743.6
7	Knee	106	40.2	4,261.2
8	Biceps	78	45.6	3,556.8
9	Finger	101	31.1	3,141.1
10	Hamstring	97	28.9	2,803.3

표 5 부상위험도가 높은 상위 10개 부상 종류

마지막으로, 부상위험도가 높은 4가지 부상의 발생 빈도와 전체 부상 발생 빈도의 합계를 비교해 보았다. <그림 9>에서 볼 수 있듯이, 모든 시즌에서 이 4가지 부상이 전체 부상의 절반가량을 차지하는 것으로 나타났다. 연구 시 39가지 부상 중 4가지 부상에만 초점을 둔다면, 전체 부상 패턴의 일부를 놓칠 수 있다는 문제점이 있을 수 있는데, 이 4가지 부상의 발생 빈도 합계는 전체 부상 발생 빈도 합계의 과반수 수준이기 때문에, 본 연구의 방향이 전체 부상에 대한 대표성을 어느 정도 유지하면서도 연구의 가치를 높일 수 있는 효과적인 접근법임을 확인할 수 있었다.




그림 9 연도별 전체부상과 상제 주요 부상 비중을 나타내는 히스토그램

위의 분석을 종합적으로 정리하면, 본 연구에서는 2017시즌부터 2022시즌까지 MLB 리그에서 발생한 부상 중 부상위험도가 높은 Shoulder(어깨), Arm(팔), Elbow(팔꿈치), 그리고 Elbow Tommy John(팔꿈치 내측 인대) 부상 중심으로, 부상 전 가까운 경기의 투구 특징에서 평소와 다른 징후를 발견하고자 한다. 이러한 방향성은 투수 부상 예방에 있어 새로운 관점을 제시하며, 부상 관리 전략 수립에 더욱 실효성 있는 도움을 줄 수 있을 것이다.

3. 데이터 전처리 및 피쳐 엔지니어링

좋은 성능의 투수 부상 예측 모델 개발을 위해서는 조금 더 복잡한 전처리 과정과 Feature Engineering을 위한 아이디어가 요구되었다.

1) 데이터전처리 및 병합

스탯캐스트 및 스포트랙 데이터를 병합한 새로운 데이터프레임을 만들기 위해 스포트랙을 통해 수집한 부상데이터에서 주요 상체 부상을 제외한 부상과 선수 이름에 결측값이 있는 경우 등의 간단한 1차 데이터 정제를 실시하였다.

동일 연도에 발생한 다수의 부상을 처리해야 했는데, 최초 데이터프레임에서 Injury 컬럼은 'Shoulder/Biceps', Dates 컬럼은 '9/8 - 10/1 4/2 - 6/8'과 같이 복수로 입력되어 있었다. 이에 str.split 함수와 정규표현식인 str.extract 함수를 사용하여 복수 입력을 각각 분리하고, 이를 신규 컬럼에 반영하여 전처리를 수행하였다.

그 외 불필요한 컬럼을 삭제하고, 스탯캐스트 데이터 기준으로 스포트랙 데이터의 컬럼명을 유사하게 변경한 후, 각 선수 id를 나타내는 'pitcher' 컬럼을 스탯캐스트 데이터에서 스포트랙 부상데이터로 맵핑시켰다. 이후 동명이인 및 결측값 처리, 부상 종류 및 발생 일자 등의 추가 전처리를 실시하여 최종 부상 데이터프레임을 완성했다.

스탯캐스트 데이터는 각 투구마다 92개 컬럼이 기록되어 있기 때문에, 투구 하나하나로 부상 예측이 가능할지에 대한 판단 근거가 필요했다. Drew Bennison, Mallet James (2021)은 투구별 변동성은 너무 커서 단일 투구로만 부상을 예측할 수 없고 게임 수준 추세에는 투수가 수행하는 방식에 대한 귀중한 정보가 포함될

가능성이 훨씬 더 크다고 했다. 이처럼 선행연구에 착안해 모든 투구 데이터를 각 경기별 평균으로 집계하여 연구를 수행하고자 한다. 이에 데이터 처리의 초기 단계에서는 투수와 경기 날짜를 기준으로 각 투수의 경기별 투구 특성에 대한 ‘release speed’, ‘effective speed’, ‘release pos x’, ‘release pos y’, ‘release pos z’, ‘release spin rate’, ‘release extension’, ‘pfx x’, ‘pfx z’, ‘plate x’, ‘plate z’, ‘vx0’, ‘vy0’, ‘vz0’, ‘ax’, ‘ay’, ‘az’, ‘spin axis’ 등의 컬럼을 선수-경기별 평균값으로 변환하였다.

또한 더미변수를 사용하여 범주형 컬럼을 모델링에 활용할 수 있는 형태로 변환하였다. 예를 들어, ‘pitch name 4-Seam Fastball’과 같이 구종을 나타내는 컬럼은 한 경기에서 구종 사용률을 ‘1’로 두고 구종별로 구사한 비율을 삽입하였고, 상대 타자가 좌타자인지 우타인지를 나타내는 ‘stand L’, ‘stand R’ 컬럼에도 각 경기에서 투수가 대결한 비율을 삽입하는 등 투구 데이터의 평균화 과정에서 손실될 수 있는 정보를 최대한 보존하려고 노력하였다.

각 투수와 경기 날짜를 기준으로 데이터를 그룹화하고, 각 그룹에 속한 행의 수를 계산하여, 각 투수의 경기별 투구 수를 집계하는 ‘pitch total number’라는 새로운 컬럼을 생성하였다. 해당 컬럼은 투수의 누적 투구량을 나타내는 지표로 본 연구에서 중요한 변수로 활용될 가능성이 있다.

투구데이터 외에도 부상데이터에서 추출한 정보를 바탕으로 추가 컬럼을 생성하였다. 먼저, 투수별로 경험한 전체 부상의 총계를 계산하였다. 데이터프레임을 투수와 부상 발생 날짜 기준으로 정렬하고, 각 투수별로 부상을 경험한 횟수를 총합하여 ‘injury total’이라는 새로운 컬럼에 할당하였다.

그리고 <표 5>에서 나타난 부상위험도가 높은 4가지 부상(‘Shoulder’, ‘Elbow’, ‘Arm’, ‘Elbow Tommy John’)을 분석하여, 각 부상 유형에 대한 총계를 계산하였다. 계산된 각 부상 유형의 총계는 ‘shoulder total’, ‘elbow total’, ‘arm total’, ‘elbow tommy john total’이라는 새로운 컬럼에 각각 할당하였고, 이 4개 부상의 총계를 뜻하는 ‘upper body injury total’ 컬럼까지 생성하여 부상 예측 성능을 높이는 데 도

움이 되는 정보로 활용하고자 하였다.

2) 예측변수 정의

지도학습(Supervised Learning) 시 부상에 영향을 준 경기와 그렇지 않은 경기를 구분하는 일관된 시점을 정하는 것은 모델의 성능을 보장하는 데 필수적이다. 이에 예측변수를 정의하기 위해서 IL 등재일로부터 어떤 시점까지를 부상 예측의 기준으로 설정하느냐를 결정해야 한다.

하지만, 실제 부상 발생 시점과 IL 등재 시점은 선수마다 상황마다 다를 수 있기 때문에, 모든 선수에게 적용될 수 있는 부상 발생에 영향을 준 경기 시점을 설정하는 것이 중요하다.

사실, 부상 예측 특성상 부상을 대비할 수 있는 기간이 길면 길수록 도움이 될 수 있다. 하지만 부상 발생 대비 시점을 너무 긴 기간으로 설정하게 되면, 모델의 예측 정확도에 문제를 일으킬 수 있으며, 실제 현장 활용도 측면에서도 유용하지 못한 결과물이 될 수 있다. Drew Bennison, Mallet James (2021) 연구에서는, 최초에 ‘경기 후 5일 이내’로 기준으로 정하고 부상 예측 실험을 실시하였으나, 데이터의 불균형 문제로 인해 ‘경기 후 14일 이내’로 예측 시점을 조정하였다고 하였다.

하지만, 본 연구는 선발투수를 포함한 모든 투수가 연구 대상이기 때문에, 특정 기간으로 부상 예측 시점을 정하는 것보다 경기 횟수로 기준을 정하는 것이 타당하다고 판단되었다. 또한, 선행연구처럼 너무 짧은 기간을 부상 예측 시점으로 설정하게 되면, 데이터 불균형 문제로 예측 모델의 성능이 떨어질 수 있기 때문에, <표 6>과 같이 ‘IL 등재 시점으로부터 가까운 5개 경기’까지를 부상 발생에 영향을 준 시점으로 기준을 설정하였다.




표 6 예측변수 클래스 설정 방식

3) 차원 축소 기법 적용

예측변수의 클래스에 따라 데이터 분포를 비교하기 위해 차원 축소 기법인 주성분 분석(PCA)와 t-SNE(t-distributed Stochastic Neighbor Embedding)을 사용하였다. 이를 통해 높은 차원의 데이터 세트를 저차원으로 변환하여 그래픽으로 시각화할 수 있는데, 예측변수의 클래스가 '0'과 '1' 일 때, 각 데이터들이 특정 공간에서 어떤 식으로 분포하고 있는지를 살펴볼 수 있다. 물론 차원 축소 기법이 항상 클래스 간 명확한 경계를 제공하는 것은 아니지만, 고차원 데이터의 경우 공간적인 특성을 명확히 이해하기 어렵기 때문에, 차원 축소 기법을 통해 데이터의 패턴과 구조를 쉽게 확인할 수 있다는 것이 특징이다.

먼저, 모든 변수(입력변수 48개 및 예측변수 1개)에 대해 정규화를 실시한 후 클래스 '0'과 '1'을 확인해 보았는데, 두 클래스 간에는 패턴이나 분포에서 특별한 차이를 보이지 않았다. 이 결과는 모든 변수를 사용하였을 때, PCA 및 t-SNE 기법이 클래스 간의 복잡한 관계를 잘 나타내지 못했음을 의미한다.

J. F. Donges et al. (2011) 연구에서는, 클라이메이트 네트워크의 공간 패턴을 분석하는 데 PCA를 사용하였는데, 상관계수가 높은 변수들을 선택하고 적용하여 복잡한 공간 구조를 몇 개의 주성분으로 요약할 수 있었다고 하였다. 이에, 다음으로는 상관관계가 높은 변수들을 활용해 보고자 피어슨 상관관계 분석(Pearson's correlation analysis)을 실시하여 상관계수가 0.01 이상인 변수 15개를 도출하였다. 이 변수들을 다시 정규화하고 PCA 및 t-SNE 3차원 분석을 실행하여 <그림 10>과 같이 시각화 결과를 도출할 수 있었다.




그림 10 PCA 3D 및 t-SNE 3D 결과

PCA와 t-SNE 결과를 살펴보면, ‘Class 0’일 때는 파랑색, ‘Class 1’일 때는 빨강 색으로, 2개 분석 모두 두 클래스 간 완벽한 구분은 이루어지지 않았지만, 일부 데이터 포인트에서는 특정 그룹이 다른 그룹과 일부 다르게 분포하는 경향을 보였다. 즉, 부상 발생에 영향을 준 경기(Class 1)에서 선수들의 투구 데이터 패턴이, 부상 발생과 관계없는 경기(Class 0)와는 약간 다르게 분포할 가능성을 시각적으로 확인 해 볼 수 있었다.

4) 커널 밀도 추정 적용

커널 밀도 추정(Kernel Density Estimation, KDE)은 비모수적인 확률 밀도 함수 추정 방법이다. 이 방법은 각 데이터 포인트에 커널 함수를 적용하여 그 결과를 합산함으로써 전체 데이터 집합의 확률분포를 추정한다. x 를 확률변수, $x_1, x_2, \dots, x_n$ 을 관측된 샘플 데이터, K 를 커널 함수라고 하면 <수식 2>와 같이 나타낼 수 있다.

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

수식 2 Kernel Density Estimation

KDE는 데이터의 분포를 시각적으로 이해하기 쉬우며, 특히 두 개 이상의 클래스가 있을 때 각 클래스에서의 변수 분포를 비교하는데 유용하다. 이에 본격적인 예측 모델 설계에 앞서, KDE를 이용하여 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1) 간 주요 변수들의 분포를 비교하고 분석하고자 한다.

분석 시에는 대표적인 2가지 상황을 설정하여, 다양한 관점에서 부상 발생 여부에 영향을 준 주요 변수를 파악해 보고자 하였다. 분석에 사용된 변수들은 총 8개로, ‘투수의 누적 투구량’(pitch total number(총 투구 수)), ‘투구 동작’(release extension mean(투수의 손에서 공이 방출될 때까지의 거리 평균), release pos y mean(투수의 손에서 공이 방출되는 위치의 y좌표 평균)), ‘투구 능력’(effective speed mean(타자에게 도달할 때의 구속 평균), release speed mean(투수의 손에서 공이 방출될 때의 구속 평균), vy0 mean(y좌표상 투구 초속 평균), ay mean(y좌표상 투구 가속도 평균)) 그리고 ‘투구 결과’(type B mean(경기에서 Ball 비율))과 같이 투수 부상에 영향을 미칠 수 있는 다양한 요소를 포괄적으로 사용하였다.

첫 번째 분석은, 전체 투수를 대상으로 실시하였다(<그림 11> 참조). 클래스 간 차이가 있었던 변수는 pitch total number(총 투구 수)였는데, pitch total number 값이 약 '30 이하'일 때 'Class 0'이 'Class 1'보다 더 많은 밀집을 보여주었고, 약 '30 이상'부터는 'Class 1'이 'Class 0'보다 더 많은 밀집이 있는 것으로 확인되었다. 즉, 부상 발생에 영향을 준 경기(Class 1)에서의 총 투구 수는, 부상 발생과 관계없는 경기(Class 0)보다 약간 많았다는 것으로 해석할 수 있다. 그 외 변수에서는 클래스 간 중심 값에서 약간의 밀집 차이만 있는 것으로 확인되었다.

다음으로는, 2017시즌부터 2022시즌 동안 부상을 가장 많이 경험한 투수를 대상으로 KDE 분석을 실시하였다(<그림 12> 참조). type B mean(경기에서 Ball 비율)을 제외한 나머지 7개 변수는, 분포의 형태(피크의 위치, 분포의 폭), 중심 경향성(평균이나 중앙 값), 분포가 겹치는 정도에서 클래스 간 큰 차이를 보였다. 즉, 부상을 많이 경험한 투수들은 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1) 간 투구 특성에서 큰 차이를 가지는 것으로 확인할 수 있었다.

위의 2가지 분석을 통해, 각 변수가 부상과 어떤 관계가 있는지, 부상과 관련 있는 경기와 관련 없는 경기에서 투구 특성이 어떻게 변하는지, 그리고 특정 집단을 설정하였을 때 어떠한 분포의 차이가 보이는지 등에 대한 이해를 할 수 있었다.

특히 '전체 투수 대상(부상 경험이 없는 투수와 상체 주요 부상을 1번 이상 경험한 투수)'의 분석에서는 변수 분포가 대부분 유사한 형태를 보였다. 하지만 동일한 변수를 사용하여 '부상을 가장 많이 경험한 투수(부상 9회)'를 분석하였을 때는, 변수 간에 큰 차이가 나타나는 것을 확인할 수 있었다. 이에 예측 모델 설계 시, 전체 선수 대상의 부상 예측뿐만 아니라 부상 경험 선수를 대상으로 부상 재발 예측 케이스를 구성하는 등의 다양한 예측 케이스를 설계하여 실험할 필요가 있을 것이다.




그림 11 전체 투수 대상 커널밀도추정 (bandwidth = 0.5)




그림 12 부상 경험이가장 많은 투수 대상 커널밀도추정 (bandwidth = 0.5)

제4장 연구방법 및 평가

1. 예측모델 수립

본 연구의 절차를 <그림 13>과 같이 시각적으로 표현하였다. 먼저, 스탯캐스트와 부상 데이터 수집 이후 데이터 정제 과정을 거쳤다. 그 과정에서 차원 축소 기법(PCA, t-SNE 3D)과 커널밀도추정(KDE) 분석을 활용하여 부상과 가까운 5경기과 그 외 경기의 투구 특성에서 발견되는 미세한 차이들도 확인하였다. 다음으로, 데이터 병합(Data Merging), 탐색(Data Exploration), 전처리(Data Preprocessing) 과정을 거치며 데이터를 모델링에 적합한 형태로 재구성하였다. 이후, 순방향 신경망(FFNN) 모델을 학습시켜 MLB 투수 상체 부상 예측 모델을 개발하고자 하였다.




그림 13 MLB 투수 상체 주요 부상 예측 모델 개발 도식

1) 실험 데이터 구성

예측에 사용된 데이터셋(Dataset)은 2017시즌부터 2022시즌까지 총 90,774개의 샘플과 49개의 변수(입력변수 48개, 예측변수 1개)로 구성되어 있다(<표 7> 참고). 학습 데이터(Train data)와 테스트 데이터(Test data)는 75%, 25% 비율로 분할하였으며, Stratify 옵션을 사용하여 원본 데이터셋의 클래스 비율이 학습 및 테스트 데이터셋에서도 동일하게 유지될 수 있도록 설정하였다. 학습 데이터는 총 68,080개의 데이터를, 테스트 데이터는 22,694개의 데이터를 사용하였으며, 학습 데이터의 10%는 학습 과정 중 검증 데이터(Validation data)로 활용하고자 하였다.

Input Features(48): p throws L mean, p throws R mean, injury experience, pitch total number, release speed mean, effective speed mean, release pos x mean, release pos y mean, release pos z mean, release spin rate mean, release extension mean, pfx x mean, pfx z mean, plate x mean, plate z mean, vx0 mean, vy0 mean, vz0 mean, ax mean, ay mean, az mean, spin axis mean, stand L mean, stand R mean, pitch name 4-Seam Fastball mean, pitch name Changeup mean, pitch name Curveball mean, pitch name Cutter mean, pitch name Eephus mean, pitch name Fastball mean, pitch name Forkball mean, pitch name KnuckleCurve mean, pitch name Knuckleball mean, pitch name PitchOut mean, pitch name Screwball mean, pitch name Sinker mean, pitch name Slider mean, pitch name Split-Finger mean, zone mean, type B mean, type S mean, type X mean, injury total, shoulder total, elbow total, arm total, elbow tommy john total, upper body injury total

Output Target(1): high risk game

표 7 예측에 사용한 입력변수 및 예측변수 종류

2) 데이터 정규화 적용

딥러닝 모델의 학습 과정은 데이터셋 내의 다양한 변수들을 파악하고 이를 바탕으로 예측을 수행하는 것이기 때문에, 각 변수의 값들이 갖는 스케일(Scale)이 크게 차이 나면 모델의 학습 효율성이 저하될 수 있다. 만약 A 변수의 값의 범위가 -10에서 10인 반면 B 변수의 값 범위가 -1000에서 1000이라고 한다면, B 변수가 전체 학습 결과에 더 큰 영향을 미치게 될 가능성이 커진다. 이에 변수들 간의 스케일 차이를 맞추는 데이터 정규화 과정이 요구된다.

데이터 정규화를 통해 학습 속도와 정확도 향상을 설명한 Raju, V. G. et al. (2020) 연구에서는, 널리 알려진 정규화 방식인 MinMaxScaler를 사용하였을 때, 정확도가 약 10% 상승하였으며, 이는 해당 연구에서 실험한 다양한 정규화 방법 중 가장 성능이 우수한 기법이었다고 설명했다. 따라서 본 연구에서도 최솟값 0에서 최댓값 1 사이의 범위로 스케일링하는 Min-Max 정규화 방법을 사용하여 모든 변수들의 값을 스케일링하고자 하였다(<수식 3> 참조).

$$x'_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

수식 3 MinMaxScaler

하지만 이 방식은 일부 제약 사항이 존재하는데, 만약 특정 변수에 이상치가 포함되어 있다면, 이상치를 최댓값 혹은 최솟값으로 인식하게 되어 정상적인 값의 분포를 왜곡시킬 수 있다. 이에 데이터 스케일링 전, 데이터 병합(Data Merging) 및 탐색(Data Exploration) 단계에서 박스 플롯(Box Plot), Z-점수, IQR(Interquartile Range) 방식을 활용하여 이상치를 탐지하였으며, 이상치에 대해서는 제거와 평균·중앙값 대체 등의 방법을 적용하여 이상치에 의한 데이터 분포의 왜곡을 최소화하고자 하였다. 이렇게 처리한 데이터를 바탕으로 Min-Max 정규화 방법을 사용하여 딥러닝 모델의 학습 데이터를 구성하였다.

3) 데이터 샘플링

본 연구에서 사용된 데이터셋은 부상 발생과 관계없는 경기(Class 0)가 전체의 95.37%를 차지하는 반면, 부상 발생에 영향을 준 경기(Class 1)는 4.63%에 불과하여, 심각한 데이터 불균형 문제를 보여준다.

Mateusz Buda et al. (2018)에 따르면, 데이터가 불균형할 경우 다수 클래스에 중점을 두고 학습하는 경향이 생기는데, 이로 인해 소수 클래스에 대한 예측 성능이 저하될 수 있다고 하였다. 본 연구에서 불균형 문제를 해결하지 않는다면, 예측 모델은 'Class 0'에 치우친 학습을 하게 되어, 'Class 1'을 제대로 분류하지 못하는 문제를 일으킬 수 있기 때문에, 사전에 데이터 불균형 문제를 해결해야 했다.

불균형 문제를 해결하기 위한 방법으로는 크게 언더샘플링(Undersampling)과 오버샘플링(Oversampling)이 있다. 언더샘플링은 다수 클래스의 데이터를 줄이는 방식으로, 실제 존재하는 데이터만을 사용하여 모델의 신뢰성을 높일 수 있다는 장점이 있지만, 중요한 정보를 잃을 가능성이 있어 모델 성능 저하의 위험이 있다 (Mateusz Buda et al., 2018). 특히 우리 데이터셋은 부상 발생에 영향을 준 경기(Class 1)의 비율이 4.63%에 불과하기 때문에, 언더샘플링 기법을 사용하게 될 시 전체 데이터의 대부분이 소실된다는 문제가 있을 수 있다.

Batista, G. E. (2004) 연구에 따르면, 클래스 간 불균형이 심한 상황을 해결하기 위해 샘플링에 대한 비교 실험을 하였는데, 오버샘플링이 언더샘플링보다 더 정확도가 높았으며, 복잡한 오버샘플링 방법보다 간단한 랜덤 오버샘플링(Random over-sampling) 방법이 더 경쟁력이 있었다고 했다.

이에 따라 본 연구에서는 데이터 불균형 문제를 해결하기 위해 다수의 클래스를 줄이는 언더샘플링 대신 소수의 클래스를 늘리는 오버샘플링 기법을 사용하였다. 그중에서도 널리 사용되는 랜덤 오버샘플링 기법 중 하나인 RandomOverSampler를

활용하였는데, 이 방법은 소수 클래스의 데이터를 무작위로 복제하여 다수 클래스의 크기에 맞추는 방식으로, 불균형한 데이터셋을 <그림 14>와 같이 균형 있는 상태로 만들어준다.




그림 14 RandomOverSampler 작동 방식

이를 통해, <표 8>과 같이 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1)의 수를 동일하게 맞추었으며, 이를 통해 모델이 각 클래스를 공평하게 학습하여 불균형한 데이터에 의해 발생할 수 있는 문제를 방지할 수 있도록 하였다.

Before oversampling	After oversampling
Class labels: [0. 1.]	Class labels: [0. 1.]
Counts: [64928 3152]	Counts: [64928 64928]

표 8 RandomOverSampler 적용 전·후의 학습데이터 내 클래스 사이즈 비교

4) 순방향 인공신경망 모델 설계

본 연구에서는 MLB 투수의 상체 주요 부상을 예측하기 위해, 딥러닝의 기본 구조 중 하나인 순방향 인공신경망(Feed forward Neural Network, FFNN)을 사용하고자 한다. FFNN의 핵심 아키텍처(<그림 15> 참조)는 입력층(Input layer), 은닉층(Hidden layer), 그리고 출력층(Output layer)으로 구성되며, 각 층 간의 데이터 흐름은 역행하지 않고 단방향으로만 흘러가는 특징이 있다.




그림 15 FFNN 모델 아키텍처(Model Achitecture)

첫 번째 단계인 입력층에서는 입력받은 데이터를 은닉층으로 전달하는 역할을 한다. 특히 입력층의 노드의 수는 입력받는 데이터의 개수와 동일하게 설정된다.

다음으로, 은닉층은 입력층 혹은 이전 은닉층으로부터 전달받은 데이터에 활성화 함수(Activation Function)를 적용하여, 정보를 다음 층으로 전달하게 된다. 여기

서 활성화 함수의 개념과 중요성을 정확히 이해하는 것이 신경망이 어떻게 복잡한 패턴을 학습하고 결과를 도출하는지 알 수 있다. 활성화 함수는 비선형 함수로 선형 함수의 제약을 극복하는 중요한 역할을 하는데, 자주 쓰이는 활성화 함수로는 Sigmoid(시그모이드, σ), Hyperbolic Tangent(하이퍼볼릭 탄젠트, $\tanh$) 그리고 Rectified Linear Unit(정류 선형 유닛, ReLU) 등이 있으며, 일반적으로 이진 분류 문제에서는 Sigmoid와 Hyperbolic Tangent 함수가 사용된다.

Sigmoid 함수는 출력 범위가 0과 1 사이라는 특징이 있고, 매끄러운 곡선을 가지고 있으므로 기울기 폭주(Gradient Exploding)가 발생하지 않는다는 장점을 가지고 있다(<수식 4> 참조). Hyperbolic Tangent 함수는 Sigmoid와 유사하지만, 출력 범위가 -1과 1 사이라는 차이가 있는데, 이로 인해 기울기가 양수, 음수 모두가 나올 수 있어 Sigmoid보다 학습 효율성이 뛰어나다는 장점이 있다(<수식 5> 참조). 하지만 두 함수 모두 큰 한계점이 존재하는데, 그것은 바로 가중치 업데이트 과정에서 발생할 수 있는 Gradient Vanishing(기울기 소실) 문제이다. 이는 역전파(Backpropagation) 과정 중 신경망의 앞부분으로 이동하면서 그래디언트가 점차 줄어들어 가중치가 실질적으로 업데이트되지 않는 현상을 말하는데, 이로 인해 모델의 학습이 잘 이루어지지 않을 수 있다.

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

수식 4 Sigmoid(σ)

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

수식 5 Hyperbolic Tangent($\tanh$)

이러한 기울기 소실 문제를 해결하기 위해 제안된 활성화 함수가 바로 Rectified Linear Unit 함수이다. 사실 Rectified Linear Unit 함수도 0 이하의 입력값에 대해서는 출력이 0이 되어 가중치 업데이트가 이루어지지 않지만, 0을 초과하는 값에

대해서는 입력받은 값을 그대로 출력한다(<수식 6> 참조). ReLU는 비선형 활성화 함수 중에서도 학습 효율성이 좋고, 기울기 소실 문제까지 해결하는 특징을 가지고 있기 때문에 널리 사용되는 활성화 함수이다.

$$ReLU(x) = \max(0, x)$$

수식 6 Rectified Linear Unit(ReLU)

마지막 출력층은, 이전 층에서 전달받은 데이터를 최종 출력 형태에 맞게 변환하여 출력하는 역할을 한다. 출력 형태는 문제의 성격에 따라 달라질 수 있는데, 본 연구에서는 이진 분류 문제를 해결하는 것이 목표이므로 출력층이 0 또는 1을 출력하도록 설정하였다.

2. 예측모델 평가

1) 예측케이스 분류

다양한 상황에 맞게 예측 케이스를 설정하고, 각각의 케이스에서 모델의 학습과 검증을 수행하는 방식은 특정 상황별 부상 위험성을 더욱 정밀하게 파악할 수 있다. 예를 들어, 선수가 과거에 상체 주요 부상(Shoulder, Arm, Elbow, Tommy John Surgery)을 경험한 적이 있는지 없는지, 부상을 경험했다면 어떤 부상을 경험하였는지에 따라 부상 발생의 위험성은 크게 달라질 수 있다. 즉, 이런 상황에 따른 차이를 고려하지 않고 모든 선수에게 일관된 모델을 적용하게 되면, 예측 모델의 성능 저하와 실제 상황에 적용 시 한계에 부딪힐 수 있다.

따라서, 본 연구에서는 <표 9>와 같이 여섯 가지 예측 케이스를 분류하여, 각각의 상황에서 상체 주요 부상 예측 모델의 성능을 평가하고자 하였다.

Case	Description	Dataset Size
1	전체 투수 대상, 상체 주요 부상 발생 예측	(90774, 49)
2	상체 주요 부상 경험 투수 대상, 상체 주요 부상 발생 예측	(34363, 49)
3	어깨 부상 경험 투수 대상, 어깨 부상 발생 예측	(17777, 49)
4	팔 부상 경험 투수 대상, 팔 부상 발생 예측	(11842, 49)
5	팔꿈치 부상 경험 투수 대상, 팔꿈치 부상 발생 예측	(10541, 49)
6	팔꿈치 내측 인대 부상 경험 투수 대상, 팔꿈치 내측 인대 부상 발생 예측	(3799, 49)

표 9 예측모델 실험 케이스 분류

‘Case 1’은 부상 경험이 없는 투수와 상체 주요 부상 경험이 있는 투수를 모두 포함하여 상체 주요 부상 발생 예측을 진행하는 경우이며, 이와는 다르게 ‘Case 2’부터 ‘Case 6’까지는 특정 부상을 경험한 선수를 대상으로, 해당 부상의 재발을 예측하는 경우를 뜻한다. ‘Dataset Size’에서 행은 ‘총 경기 수’를, 열은 ‘예측에 사용될 변수의 수’를 의미한다. 이처럼, 투수의 과거 부상 이력과 같은 중요한 정보를 활용하여 여러 부상 상황에 대응할 수 있는 다양한 예측 모델을 만들고자 한다.

2) 하이퍼파라미터 설정

딥러닝 모델의 성능은 하이퍼파라미터 설정에 따라 크게 좌우될 수 있다. Bergstra, J. et al. (2012)는 모델링의 혁신이나 기계학습 전략보다 오히려 하이퍼파라미터 최적화가 저성능 알고리즘에서도 이미지 분류 문제를 해결할 시에 더 좋은 성능을 만들어 낼 수 있다고 강조하였다. 이것은 고성능 알고리즘조차도 적절한 하이퍼파라미터 설정 없이는 저성능 알고리즘보다 나쁜 결과를 초래할 수 있다는 점을 시사한다. 따라서 본 연구에서도 하이퍼파라미터를 최적화하기 위해 <표 10>과 같이 하이퍼파라미터별 범주와 옵션의 기준을 세우고 실험을 진행하고자 하였다.

Category	Options
Number of Neurons	32, 64, 128, 256
Number of Layers	3, 4, 5, 6
Activation Function	ReLU, Sigmoid, Tanh
Optimizer	Adam
Loss Function	binary crossentropy
Learning Rate	0.001, 0.01
Epoch	20, 30, 50, 100
Batch Size	32, 64

표 10 하이퍼파라미터 튜닝 케이스

노드 수(Number of Neurons)는 32, 64, 128, 256 중에서 선택하였으며, 은닉층의 수(Number of Layers)는 최소 3개에서 최대 6개로 설정하였다. 이런 노드 수와 은닉층의 수는 모델의 복잡성을 조절한다.

활성화 함수(Activation Function)는 주로 ReLU를 사용하되, 추가로 Sigmoid와 Tanh도 검증하고자 하였다. 활성화 함수는 신경망에서 출력을 결정하며, 비선형성을 도입해 신경망이 복잡한 패턴을 학습할 수 있게 한다.

옵티마이저(Optimizer)는 모델의 가중치를 업데이트하는 방법을 결정하며, 이는 손실함수에 따른 모델의 성능 개선에 결정적인 역할을 하는데, 본 연구에서는 일반적으로 빠르고 안정적인 옵티마이저로 알려진 아담(Adam)을 사용하였다.

그 외에도 손실 함수(Loss Function)로는 binary Cross Entropy를 사용하였으며 (<수식 7> 참조), 모델 학습의 반복 횟수(Epoch)와 배치 크기(Batch Size)는 초기 설정값으로 20과 32로 설정하여 실험하였고, 각각 30, 50, 100과 64를 추가로 실험하여 가장 효과적인 조합을 찾아내는 것을 목표로하였다.

$$BCE = -(y \log(p) + (1 - y) \log(1 - p))$$

수식 7 Binary Cross Entropy

마지막으로, 학습 과정에서 일정 횟수 이상의 반복이 추가적인 학습 향상에 큰 의미를 두지 않는 시점을 파악하기 위해 조기 종료(Early Stopping) 기법까지 적용하였다.

본 연구는 MLB 투수의 상체 주요 부상을 예측하는 문제를 해결하기 위해 여섯 가지 케이스별로 최적의 성능을 추출하기 위한 목표를 가지고 있다. 이를 달성하기 위해, 각 케이스별로 다양한 하이퍼파라미터 설정에 대한 실험을 진행하였다. 이 과정을 통해, 각 케이스에 가장 효과적인 하이퍼파라미터 조합을 도출하고, 이를 기반으로 투수의 부상 예측 모델을 최적화하고자 한다.

3) 성능 평가 지표

본 연구는 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1)를 분류하는 문제로, 모델의 정확한 성능 평가를 위해 다양한 지표를 사용하였다. 모델의 성능을 직관적으로 평가하는 데 효과적인 정확도(Accuracy)를 기반으로, 정밀도(Precision), 재현율(Recall) 및 F1 Score와 Macro F1 Score, AUC-ROC Curve를 활용하고자 하며, 각각의 지표에 대한 설명은 다음과 같다.

먼저, Accuracy는 전체 케이스 중에서 올바르게 예측한 케이스의 비율을 나타낸다. 즉 모델이 얼마나 정답을 분류하는지를 나타내는 지표이며, <수식 8>과 같이 표현될 수 있다.

$$Accuracy = \frac{\sum TP + \sum TN}{\sum TP + \sum TN + \sum FP + \sum FN}$$

수식 8 Accuracy

Precision은 True로 분류한 케이스 중에서 실제로 True인 케이스의 비율을 나타낸다. 즉 모델이 얼마나 정확하게 True를 분류하는지를 나타내는 지표이며, <수식 9>와 같이 나타낼 수 있다.

$$Precision = \frac{\sum TP}{\sum TP + \sum FP}$$

수식 9 Precision

Recall은 실제로 True인 케이스 중에서 모델이 True로 분류한 케이스의 비율을 나타낸다. 이는 모델이 실제 True 케이스를 얼마나 잘 포착하는지를 나타내는 지표이며, <수식 10>과 같이 표현될 수 있다.

$$Recall = \frac{\sum TP}{\sum TP + \sum FN}$$

수식 10 Recall

F1 Score는 Precision과 Recall의 조화평균이다. 두 지표 사이에는 일반적으로 Trade-off 관계가 있어서, 하나를 높이면 다른 하나가 낮아지는 경향이 있다. 즉, 지표의 균형을 나타내는 데 유용하며, <수식 11>과 같이 나타낼 수 있다.

$$F1\ Score = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

수식 11 F1 Score

F1 Score가 1개의 클래스에 대해 점수를 측정하는 방식인 데 반해, Macro F1 Score는 모든 클래스에 대해 F1 Score를 계산하고 이를 평균 내는 방법을 취한다. 이는 모든 클래스의 중요성을 동일하게 간주하기 때문에 클래스 불균형 문제를 다루는 데 유용하다. 본 연구에서 사용된 데이터셋은 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1)의 비율이 각각 95.37%, 4.63%로, Class 0의 비율이 높은 심각한 데이터 불균형을 보이기 때문에, F1 Score보다 Macro F1 Score가 전체적인 성능을 평가하는 데 더 유용하다(<수식 12> 참조).

$$Macro\ F1\ Score = \frac{1}{N} \sum_{i=0}^N F1\ Score\ (N : The\ Number\ of\ Classes)$$

수식 12 Macro F1 Score

마지막으로, ROC 곡선은 False Positive Rate에 대한 True Positive Rate를 그래프로 표현한 것이다. AUC는 이 ROC 곡선 아래의 영역의 넓이를 뜻하는데, 이 값이 1에 가까울수록 모델의 분류 성능이 완벽에 가깝다고 할 수 있고, 0.5에 가까울수록 무작위 추측 수준의 성능을 보인다고 볼 수 있다.

이처럼, MLB 투수 상체 주요 부상 예측 모델의 성능을 정확하게 평가하기 위해

다양한 평가 지표를 사용하고자 하였다. 이러한 평가 지표들의 결과를 종합적으로 고려한다면, 본 모델의 예측력 검증에 대해 신뢰 수준을 높일 수 있을 것이다.

3. 예측모델 결과

본 연구에서는 여섯 가지 케이스에 대해 MLB 투수 상체 주요 부상 예측을 수행하였다. 모든 케이스에서 FFNN 모델을 사용하였으며, <표 10>에 제시한 하이퍼파라미터 설정 옵션 모두를 실험하였다. 기본적으로 설정한 Optimizer 및 Loss Function 외에도, 공통적으로 Activation Function은 ReLU, Optimizer는 Adam, Learning Rate는 0.001, Batch Size는 32 그리고 Epochs는 30을 적용했을 때 일반적으로 성능 수준이 우수한 편이었다. 따라서 기본 하이퍼파라미터 적용 후 나머지 하이퍼파라미터를 조정하면서, 각 케이스별로 가장 높은 성능을 보여준 5가지 조합과 Macro F1 Score 기준에서의 결과를 <표 11>와 같이 정리하였다.

‘Case 1’은 전체 투수 대상으로 상체 주요 부상 발생을 예측하는 경우로, 은닉층 4개 및 노드 수 64-128-128-64로 설정하였을 때 가장 성능이 높았다. ‘Case 2~6’은 부상 경험 선수를 대상으로 해당 부상 발생을 예측한 경우로, 각 케이스마다 최적의 하이퍼파라미터 조합으로는 ‘Case 2’는 은닉층 4개 및 노드 수 64-128-64-32, ‘Case 3’은 은닉층 5개 및 노드 수 64-128-64-32-16, ‘Case 4’는 은닉층 4개 및 노드 수 64-128-64-32, ‘Case 5’는 은닉층 4개 및 노드 수 64-128-128-64, 마지막으로 ‘Case 6’은 은닉층 4개 및 노드 수 64-128-64-32였다.

각 케이스별 성능을 비교해 보면, 가장 성능이 높았던 케이스는 ‘Case 6’, 가장 성능이 낮았던 케이스는 ‘Case 1’이었다. 다음은 각 케이스별로 하이퍼파라미터 최적화를 적용한 후 예측 모델의 상세 결과를 정리하였다.

Case	No.	Layers	Neurons	Macro F1
1	1	4	64-128-64-32	0.585
	2	4	64-128-128-64	0.607
	3	5	64-128-64-32-16	0.583
	4	4	128-256-128-64	0.599
	5	6	64-128-256-128-64-32	0.605
2	1	4	64-128-64-32	0.647
	2	4	64-128-128-64	0.629
	3	5	64-128-64-32-16	0.642
	4	4	128-256-128-64	0.639
	5	6	64-128-256-128-64-32	0.639
3	1	4	64-128-64-32	0.606
	2	4	64-128-128-64	0.592
	3	5	64-128-64-32-16	0.624
	4	4	128-256-128-64	0.618
	5	6	64-128-256-128-64-32	0.595
4	1	4	64-128-64-32	0.681
	2	4	64-128-128-64	0.676
	3	5	64-128-64-32-16	0.651
	4	4	128-256-128-64	0.667
	5	6	64-128-256-128-64-32	0.642
5	1	4	64-128-64-32	0.646
	2	4	64-128-128-64	0.693
	3	5	64-128-64-32-16	0.632
	4	4	128-256-128-64	0.673
	5	6	64-128-256-128-64-32	0.657
6	1	4	64-128-64-32	0.740
	2	4	64-128-128-64	0.702
	3	5	64-128-64-32-16	0.649
	4	4	128-256-128-64	0.718
	5	6	64-128-256-128-64-32	0.695

표 11 각 케이스별 하이퍼파라미터 조정에 따른 성능 결과 비교

1) 전체 투수 대상, 상체 주요 부상 예측

‘Case 1’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 90.7%로, 전체 22,694경기 중 약 20,583경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.968	0.933	0.950	21643
1	0.208	0.363	0.264	1051
accuracy				22694
macro avg	0.588	0.648	0.607	22694

표 12 [Case 1] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 12> 참조), 부상이 없는 경우(Class 0)에는 정밀도 96.8%, 재현율 93.3%, F1 Score 0.950으로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도 20.8%, 재현율 36.3%, F1 Score 0.264로 나타났다.




그림 16 [Case 1] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 16>은 ‘Case 1’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 63.7%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 6.7%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.81로 나타났다.

전체 투수를 대상으로 상체 주요 부상 발생을 예측한 ‘Case 1’의 경우는, 모델이 부상이 없는 경우(Class 0)를 정확하게 예측하는 데는 뛰어난 성능을 보여주지만, 부상이 있는 경우(Class 1)는 상대적으로 낮은 성능을 나타내었다. 하지만 부상 경험이 전혀 없는 선수까지 포함한 실험이었다는 것을 가정할 때, 부상 발생 예측 재현율 36.3%는 모델의 성능이 유의미하다는 것을 나타낸다고 할 수 있다.

2) 상체 주요 부상 경험 선수 대상, 상체 주요 부상 예측

‘Case 2’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 93.1%로, 전체 8,591경기 중 약 7,998경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.967	0.960	0.964	8173
1	0.313	0.352	0.331	418
accuracy				8591
macro avg	0.640	0.656	0.647	8591

표 13 [Case 2] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 13> 참조), 부상이 없는 경우(Class 0)에는 정밀도 96.7%, 재현율 96.0%, F1 Score 0.964로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도

31.3%, 재현율 35.2%, F1 Score 0.331로 나타났다.




그림 17 [Case 2] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 17>은 ‘Case 2’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 64.8%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 4.0%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.83로 나타났다.

상체 주요 부상 경험 선수를 대상으로 상체 주요 부상 발생을 예측한 ‘Case 2’의 경우에서도, 부상이 있는 경우(Class 1)는 낮은 성능을 기록하며 모델이 부상 투수를 식별하는 능력이 높지 않음을 보였다. 그러나, 이미 부상을 한 번 이상 경험한 투수가 부상 재발 위험을 감지한다는 관점에서 보면, 정밀도, 재현율, F1 Score가 모두 0.30을 초과한 결과를 나타냈으므로 이는 충분히 의미 있는 인사이트를 제공했다고 볼 수 있다.

3) 어깨 부상 경험 선수 대상, 어깨 부상 예측

‘Case 3’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 93.3%로, 전체 4,445경기 중 약 4,147경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.962	0.968	0.965	4225
1	0.301	0.268	0.284	220
accuracy				4445
macro avg	0.632	0.618	0.624	4445

표 14 [Case 3] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 14> 참조), 부상이 없는 경우(Class 0)에는 정밀도 96.2%, 재현율 96.8%, F1 Score 0.965로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도 30.1%, 재현율 26.8%, F1 Score 0.284로 나타났다.




그림 18 [Case 3] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 18>은 ‘Case 3’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 73.2%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 3.2%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.80으로 나타났다.

어깨 부상 경험 선수를 대상으로 어깨 부상을 예측한 ‘Case 3’의 경우에는, ‘Case 2’의 부상 발생 성능 평가 지표보다 모든 영역에서 낮은 수치를 기록하였다. 어깨 부상은 부상 신호가 크게 나타날 것이라는 예상과는 달리, 어깨 부상에 대해 명확한 투구 특성을 발견하기 어려웠던 것으로 판단되었다. 하지만 본 연구에서도 부상을 예측하고 실제 발생하는 비율을 나타내는 정밀도는 30.1%를 기록하였다.

4) 팔 부상 경험 선수 대상, 팔 부상 예측

‘Case 4’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 92.1%로, 전체 2,961경기 중 2,727경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.974	0.942	0.957	2810
1	0.328	0.530	0.405	151
accuracy				2961
macro avg	0.651	0.736	0.681	2961

표 15 [Case 4] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 15> 참조), 부상이 없는 경우(Class 0)에는 정밀도 97.4%, 재현율 94.2%, F1 Score 0.957로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도

32.8%, 재현율 53.0%, F1 Score 0.405로 나타났다.




그림 19 [Case 4] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 19>는 ‘Case 4’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 47.0%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 5.8%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.85로 나타났다.

팔 부상 경험 선수 대상으로 팔 부상을 예측한 ‘Case 4’의 경우에는, 부상이 있는 경우(Class 1)의 성능이 많이 향상된 모습을 보였다. 특히 재현율에서 53.0%를 기록하였는데, 2번 중 1번 이상으로 팔 부상을 감지할 수 있다는 것으로 해석할 수 있다. 이는 팔 부상을 신속하게 예측하는 데에 있어서 모델의 효과적인 활용 가능성을 시사한다. ‘Case 4’ 연구는 팔 부상 예측을 위한 모델 개발에 있어서 매우 유용한 결과를 제시한 것으로 사료된다.

5) 팔꿈치 부상 경험 선수 대상, 팔꿈치 부상 예측

‘Case 5’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 93.6%로, 전체 2,636경기 중 2,467경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.969	0.963	0.966	2499
1	0.399	0.445	0.421	137
accuracy				2636
macro avg	0.684	0.704	0.693	2636

표 16 [Case 5] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 16> 참조), 부상이 없는 경우(Class 0)에는 정밀도 96.9%, 재현율 96.3%, F1 Score 0.966으로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도 39.9%, 재현율 44.5%, F1 Score 0.421로 나타났다.




그림 20 [Case 5] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 20>은 ‘Case 5’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 55.5%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 3.7%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.86으로 나타났다.

팔꿈치 부상 경험 선수 대상으로 팔꿈치 부상을 예측한 ‘Case 5’의 경우에서도, 부상이 있는 경우(Class 1)의 성능이 많이 향상된 모습을 보였다. 특히 부상 발생 예측에 관한 정밀도 값이 0.40에 근접했고, 재현율 및 F1 Score 값은 모두 0.40을 초과하였다. 또한 세 지표 값이 모두 비슷한 수치를 보였는데, 이는 ‘Case 5’ 모델이 정확성과 감지 능력을 균형 있게 가지고 있다는 것을 시사한다고 할 수 있다.

6) 팔꿈치 내측 인대 부상 경험 선수 대상, 팔꿈치 내측 인대 부상 예측

‘Case 6’ 모델의 성능을 평가한 결과, 정확도(Test Accuracy)는 94.7%로, 전체 950경기 중 약 900경기에서 투수의 부상 여부를 정확하게 예측했다.

	precision	recall	f1-score	support
0	0.982	0.963	0.972	908
1	0.433	0.619	0.510	42
accuracy				950
macro avg	0.708	0.791	0.741	950

표 17 [Case 6] Classification Report

각 클래스별로 정밀도(Precision), 재현율(Recall) 및 F1 점수(F1-Score) 결과를 확인해 보면(<표 17> 참조), 부상이 없는 경우(Class 0)에는 정밀도 98.2%, 재현율 96.3%, F1 Score 0.972로 나타났다. 반면, 부상 있는 경우(Class 1)에는 정밀도

43.3%, 재현율 61.9%, F1 Score 0.510으로 나타났다.




그림 21 [Case 6] (좌) Confusion Matrix, (우) ROC Curve & AUC

<그림 21>은 ‘Case 6’ 모델의 혼동행렬(Confusion Matrix) 및 ROC Curve & AUC를 활용한 성능 평가 결과이다. 먼저 혼동행렬을 살펴보면, 모델이 부상 없음으로 예측했지만, 실제로는 부상이 발생한 경우의 비율을 나타내는 ‘False Negative(왼쪽 아래)’는 38.1%의 비율을 보였고, 모델이 부상 발생으로 예측했지만, 실제로는 부상이 없었던 경우의 비율인 False Positive(오른쪽 위)는 약 3.7%의 비율을 보였다. 다음 ROC Curve & AUC 결과에서는 AUC가 0.93으로 나타났다.

‘Case 6’에서는 팔꿈치 내측 인대 부상 경험 선수 대상으로 해당 부상 예측을 수행했고, 이는 모든 케이스 중에서 가장 높은 성능을 보여주었다. 특히, 부상 발생 예측에 관한 정밀도 43.3%, 재현율 61.9% 등 모든 부상 예측 지표에서 가장 높은 성능을 나타내었다. 이러한 결과는 팔꿈치 내측 인대 부상에 대한 우리의 예측 모델이 매우 정확하게 작동함을 증명하며, 실제 경기에서 이 모델을 통해 해당 부상에 리스크가 있는 투수를 미리 식별하고, 적절한 예방 조치를 취하는 것이 가능한 수준이라 사료된다.

제5장 논의

1. 연구 결과 요약

본 연구에서는 스탯캐스트와 부상 데이터를 기반으로 투수 부상 예측을 위한 FFNN(Feed Forward Neural Network) 모델을 개발하였다. 본 연구에서 예측 모델의 성능을 평가하기 위해 여섯 가지 케이스를 분류하고 비교하였으며, 각 케이스는 MLB 투수의 상체 주요 부상 예측하는 데 유의미한 성능을 보여주는 것으로 확인되었다. 다음은 각 성능 평가 지표별로 여섯 가지 케이스를 비교한 결과이다.

첫 번째, ‘정확도(Test Accuracy)’는 모델의 전반적인 성능을 나타내는 지표이다. 본 연구 결과에 따르면, ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 가장 높은 정확도인 94.7%를 보였다. 그다음으로 ‘Case 5’ 팔꿈치 부상 경험 선수 93.6%, ‘Case 3’ 어깨 부상 경험 선수 93.3%, ‘Case 2’ 상체 주요 부상 경험 선수 93.1%, ‘Case 4’ 팔 부상 경험 선수 92.1%, 마지막으로 ‘Case 1’ 전체 투수 대상 90.7% 순으로 나타났다.

연구에서 사용한 여섯 가지 케이스 모두 정확도가 90% 이상이었으므로 모든 케이스에서 모델이 전반적으로 부상 여부를 잘 예측한다고 볼 수 있다. 다만, 본 연구에서는 클래스 간 불균형이 심한 데이터를 사용했기 때문에, 정확도만으로 모델의 성능을 이해하기에는 한계가 있다.

두 번째, ‘정밀도(Precision)’는 모델이 부상을 예측했을 때 그 예측이 얼마나 정확한지를 반영하는 지표로, 투수의 부상 예방에 있어서 이 지표가 높을수록 실제 투수의 부상 예측에 효과적이라 할 수 있다. 부상 있는 경우(Class 1)에 대한 정밀도 결과는, ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 43.3%로 가장 높은 정밀도를 보였다. 그다음으로는 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때가 39.9%였다. 이어서 ‘Case 4’ 팔 부상 경험 선수 대상일 때 32.8%, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 31.3%, ‘Case 3’ 어깨 부상 경험 선수 대상일 때 30.1%, 마지막으로 ‘Case 1’ 전체 투수 대상일 때 정밀도가 20.8%로 나타났다.

‘Case 1’을 제외한 나머지 경우에는, 모델이 부상이 발생할 것이라고 예측했을 때 3번 중 1번 수준으로는 실제 부상이 발생한다는 것을 의미한다. 이 결과는 실제 현장에서도 무시할 수 없는 수치라고 사료된다.

세 번째, ‘재현율(Recall)’은 실제 부상 사례 중 얼마나 많은 부상을 모델이 정확하게 감지했는지를 보여주는 중요한 지표로 모델의 ‘감지 능력’을 반영한다. 즉, 재현율이 높을수록 모델은 실제 부상 사례를 놓치는 경우가 적어, 투수의 부상을 미리 예방하는 데 있어서 중요한 역할을 한다고 할 수 있다. 부상 있는 경우(Class 1)에 대한 재현율 결과는, ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 연구가 61.9%로 가장 높았다. 그다음으로 높은 재현율을 보인 경우는 ‘Case 4’로, 팔 부상 경험 선수를 대상으로 했을 때의 재현율이 53.0%였다. 이후 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때 44.5%, ‘Case 1’ 전체 투수 대상이 36.3%, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 35.2%, 마지막으로 ‘Case 3’ 어깨 부상 경험 선수가 대상일 때 26.8%로 나타났다.

‘Case 6’과 ‘Case 4’의 경우는, 모델이 실제 부상 사례 중 1/2 이상을 성공적으로 감지하였다고 볼 수 있으며, 그 외에도 ‘Case 3’을 제외한 나머지 Case는 1/3 이상을 성공적으로 포착하는 성능을 보여주었다고 할 수 있다.

네 번째, ‘F1 점수(F1-Score)’는 정밀도와 재현율의 조화 평균으로, 이 두 가지 지표의 균형을 나타내며 이진 분류 모델의 성능 평가 시 자주 활용된다. 부상 있는 경우(Class 1)에 대한 F1 점수로, ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 가장 높은 F1 점수 0.510을 보였으며, 그다음으로는 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때 0.421, ‘Case 4’ 팔 부상 경험 선수 대상일 때 0.405, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 0.331, ‘Case 3’ 어깨 부상 경험 선수 대상일 때 0.284, ‘Case 1’ 전체 투수 대상일 때 0.264 순으로 나타났다.

‘Case 6’이 가장 높은 F1 점수를 보였다는 것은 정밀도와 재현율 둘 다 좋은 성능을 보였음을 의미하며, ‘Case 5’와 ‘Case 4’ 역시 팔꿈치 부상과 팔 부상에 대한 예측으로 정밀도와 재현율의 조화가 우수했다는 것으로 해석할 수 있다.

마지막으로, ROC 곡선과 AUC를 이용한 모델의 성능 평가에서는 ROC 곡선 아래 면적인 AUC를 활용하여 이진 분류 모델의 성능을 나타내고자 하였다. 본 연구 결과에서는 ‘Case 6’ 팔꿈치 내측 인대 부상 경험 선수를 대상으로 한 경우가 0.93으로 가장 높은 AUC 값을 보였다. 이어서 ‘Case 5’ 팔꿈치 부상 경험 선수 대상일 때 0.86, ‘Case 4’ 팔 부상 경험 선수 대상일 때 0.85, ‘Case 2’ 상체 주요 부상 경험 선수 대상일 때 0.83, ‘Case 1’ 전체 투수 대상일 때 0.81, 마지막으로 ‘Case 3’ 어깨 부상 경험 선수 대상일 때 0.80으로 나타났다.

AUC 값은 1에 가까울수록 완벽한 분류 성능을, 0.5에 가까울수록 무작위 추측 수준의 성능을 나타내기 때문에, 여섯 가지 케이스 모두 무작위 추측보다 뛰어났으며, 모델이 상당히 좋은 분류 성능을 보여주고 있다고 해석할 수 있다.

성능 평가 결과를 종합하면, ‘Case 6’ (팔꿈치 내측 인대 부상 경험 선수), ‘Case 5’ (팔꿈치 부상 경험 선수), ‘Case 4’ (팔 부상 경험 선수), ‘Case 2’ (상체 주요 부

상 경험 선수), 'Case 3' (어깨 부상 경험 선수), 'Case 1' (전체 투수 대상) 순으로 예측 성능이 높았다. 이 결과는 모델이 팔꿈치와 팔 부상과 관련된 경우에 상대적으로 더 강한 예측 능력이 있음을 보여준다. 그러나, 모델의 전반적인 부상 예측 정확도는 아직 완벽하지 않기 때문에, 구단이나 선수에게 불필요한 경계를 일으키거나, 투수의 등판 문제에 혼란을 초래할 수도 있다. 이런 점을 고려할 때, 부상 예측에 있어서는 여전히 성능 향상의 필요성이 있다.

2. 유사 연구와의 비교

본 논문의 연구 아이디어가 된 Drew Bennison, Mallet James (2021) 연구에서는, 2015시즌부터 2020시즌까지의 Statcast 데이터와 기계학습 분야의 XGBoost Classifier 모델을 활용하여 선발투수 대상으로 모든 상체 부상에 대한 예측 연구를 수행하였다.

선행연구와 본 연구에서 선행연구와 비슷한 조건에서 실험한 'Case 1(모든 선수 대상의 부상 예측)' 간의 결과를 비교해보면, 전반적으로 본 모델의 예측 성능이 선행연구보다 더 우수한 것으로 확인되었다(<표 18> 참조).

Predicting MLB Pitcher Injuries With Statcast Data (2021)				
Actual Class	precision	recall	f1-score	support
Not-Injured (0)	0.97	0.90	0.93	4103
Injured (1)	0.12	0.31	0.17	180
스탯캐스트와 딥러닝을 활용한 MLB 투수 부상 예측에 관한 연구 (2023)				
Actual Class	precision	recall	f1-score	support
Not-Injured (0)	0.968	0.933	0.950	21643
Injured (1)	0.208	0.363	0.264	1051

표 18 선행연구 & 본 연구 간 결과 비교

각 성능 평가 지표별로 두 연구 간의 결과를 비교해 보면, 먼저, 정밀도(Precision)의 경우, Class 0(부상 없음)에서는 선행연구 97%, 본 연구 96.8%로 두 연구 모두 매우 높은 수치를 보였다. Class 1(부상 있음)에서는 선행연구가 12%인데 반해 본 연구는 20.8%로, 부상을 정확하게 예측하는 성능이 8.8% 향상되었다. 이는 본 모델이 선행연구에 비해 실제 부상이 발생한 경우를 더 정확하게 예측할 수 있다는 것을 의미한다.

재현율(Recall)의 경우, Class 0(부상 없음)에서 선행연구는 90%, 본 연구는 93.3%로 본 연구가 3.3% 더 높았고, Class 1(부상 있음)에서도 선행연구는 31%인데 반해 본 연구는 36.3%를 기록하며, 5.3% 더 높은 성능을 보여주었다. 이는 본 모델이 선행연구보다 부상 예측에 있어 전체적인 신뢰도가 더 높음을 보여준다고 할 수 있다.

F1-점수(F1-score)는 정밀도와 재현율의 조화 평균으로, Class 0(부상 없음)에서는 선행연구가 0.93, 본 연구가 0.95로 본 연구가 약간 더 높았다. Class 1(부상 있음)에서도 선행연구는 0.17인데 반해 본 연구는 0.264를 나타내며 성능이 크게 향상된 것을 확인할 수 있었다. 이는 본 모델이 부상 예측에 있어 전체적인 정확도와 신뢰도 모두 향상되었음을 나타낸다고 할 수 있다.

종합적으로 볼 때, 본 연구는 선행연구에 비해 Class 1(부상 있음)에 대한 예측 성능이 크게 향상되었으며, Class 0(부상 없음)에 대한 성능도 소폭 개선되었다. 이러한 성과는 본 연구에서 더 큰 규모의 데이터셋을 사용하였고, 최적화된 딥러닝 모델 및 학습 방법을 적용한 결과라고 볼 수 있다. 이를 통해, 투수의 부상 위험을 더욱 정확하게 파악하고, 효과적인 부상 예방 전략을 수립하는 데 큰 도움이 될 것으로 예상된다.

다만, 아직까지 Class 1(부상 있음)을 정확히 예측하는 성능은 높지 않아 향후 개선의 여지는 있다. 하지만 선행연구와 비교했을 때, 본 연구는 ‘선발투수’만이 아닌 ‘전체 투수’를 대상으로 연구했다는 점, ‘모든 상체 부상’이 아닌 ‘부상위험도가

높은 주요 상체 부상'을 집중하여 연구했다는 점, 그리고 여섯 가지 예측 케이스를 설계하여 다양한 경우를 평가했다는 점 등에서 개선된 연구를 했다고 볼 수 있다.

3. 정확도가 낮은 이유에 대한 분석

다수의 기계학습 알고리즘은 균형 잡힌 데이터를 가정하고 설계되었기 때문에, 본 연구에서 사용된 데이터셋과 같이 극단적으로 불균형한 데이터에서는 성능이 크게 떨어질 수 있다. 이러한 문제는 흔히 클래스 불균형 문제라고 불린다(He & Garcia, 2009). 본 연구에서 높은 정밀도를 달성하지 못한 원인 중 하나는 이러한 데이터 불균형 때문일 것으로 사료된다.

'Case 1'에서 부상 발생과 관계없는 경기(Class 0)와 부상 발생에 영향을 준 경기(Class 1)의 데이터 비율은 각각 약 95%, 5%였다. 이로 인해, 모델은 부상과 관계없는 경기를 예측하는 것에 치우칠 수 있고, 이는 알고리즘이 부상과 연관이 된 경기에 대한 패턴을 충분히 학습하지 못하게 만들어 부상 예측 성능을 저하시킨 것으로 보여진다.

본 연구에서는 불균형 데이터 문제를 완화하기 위해 오버샘플링(Oversampling) 기법 중 RandomOverSampler를 적용하였음에도 불구하고, 여전히 부상을 정확히 예측하는 데 있어서 낮은 성능을 보였다. 이러한 문제를 근본적으로 해결하기 위해서는 새로운 데이터 수집과 생성이 중요할 것으로 보인다. 그 외에도 시계열 데이터, 영상 동작 분석 데이터 등을 활용하여 '부상'과 '비부상'을 더 명확하게 구분해 낼 수 있는 피처 엔지니어링(Feature Engineering)에 대한 추가 연구도 필요할 것으로 사료된다.

제6장 결론 및 제언

본 연구는 2017시즌부터 2022시즌까지 MLB Statcast에서 제공하는 데이터와 몇 가지 부상 정보를 활용하여, 투수의 신체 주요 부상에 대해 초기 경고를 할 수 있는 딥러닝 모델을 제시하였다.

이전의 연구들은 주로 부상 요인을 식별하거나 시즌 단위로 부상을 예측하려는 시도를 보였지만, 본 연구는 투수들의 투구 횟수, 회전율, 릴리스스피드 변화 및 이전 부상 경험 여부 등을 분석하고 특정 패턴을 찾아내어, 경기 단위로 부상을 예측하는 새로운 접근 방식을 시도하였다.

FFNN을 사용한 본 모델은, 투수가 경기 후 5경기 이내에 신체 주요 부상을 입을지에 대한 여부를 분류하였는데, 전체 선수 대상 연구에서는 Macro F1-Score 0.61, 신체 주요 부상 경험 선수 대상 연구에서는 Macro F1-Score 0.65, 어깨 부상 경험 선수 대상 연구에서는 Macro F1-Score 0.62, 팔 부상 경험 선수 대상 연구에서는 Macro F1-Score 0.68, 팔꿈치 부상 경험 선수 대상 연구에서는 Macro F1-Score 0.69, 팔꿈치 내측 인대 재건술 경험 선수 대상 연구에서는 Macro F1-Score 0.74로 가장 높은 성능을 보여주었다.

실제로 ‘부상 위험에 처해 있는지’, ‘적절한 휴식이 필요한지’, ‘투구 스타일을 조정해야 하는지’와 같은 중대한 결정은 코치, 감독, 팀 닥터 등의 판단에 의해 이루어질 것이다. 하지만, 본 연구에서 개발한 예측 모델은 투구의 특성들과 몇 가지 부상 정보만으로, 이러한 결정에 정량적으로 참조할 수 있는 자료를 제공할 수 있다는 점에서 큰 의미를 가진다.

더불어, 본 연구에서는 상황에 따른 여섯 가지 예측 케이스를 구분하여 모델을

구축하였는데, 세부적인 부상 유형을 모델에 반영하는 것이 전반적인 예측 성능을 향상시키는 데 중요함을 확인할 수 있었다. 또한 각 케이스별 연구 결과는, 실제 구단에서 선수 개개인의 부상 위험성에 대해 더 깊이 이해하고, 효과적인 대응 전략을 제공하는 데 도움을 줄 수 있을 것이다.

하지만 예측 모델이 MLB 투수들의 출전 여부를 판단하는 결정적인 도구로 활용되기 위해서는 성능 개선이 필수적이다. 이에, 후속 연구에서는 다음과 같은 방식으로 모델의 성능 향상을 위한 연구를 이어 나가하고자 한다. 첫째, 나이와 같은 선수 기본 정보, 경기에서 주자 상황 등의 통계, 경기 일정 밀도, 투수의 레퍼토리 변화 등과 같은 변수를 추가한다면 모델의 예측력을 향상시키는 데 도움이 될 것이다. 둘째, 투수의 부상은 피로 누적 등 시간에 따른 누적 요인에 의해 발생한 경우가 많을 수 있다. 따라서 시계열 분석이나 롤링 통계와 같은 기법을 추가로 활용한다면 더 나은 모델을 제시할 수 있을 것이다. 마지막으로, 의학적인 관점에서 투수 부상을 더 깊이 이해하려는 노력을 통해, 의료진과 협력하여 어떤 요인들이 부상을 일으키는지를 더 탐구하고, 핵심 변수를 데이터셋에 반영할 필요가 있다. 이는 모델의 예측력을 향상시키고, 부상에 영향을 미치는 다양한 요인을 더 잘 이해하는 데 도움이 될 것이라 사료된다.

최종적으로, 본 연구의 결과는 딥러닝을 통해 기존에 없던 신선한 접근 방법을 통해 투수의 부상을 예측할 수 있는 가능성을 보여주었다. 아직 성능 개선의 여지는 있지만 이 모델은 향후 더욱 정밀한 투수 부상 예측 모델 개발에 도움이 될 수 있을 것이다. 이를 통해, 구단에서 투수의 부상을 사전에 예방하고, 더 안전하고 효과적인 투수 관리 전략을 구현하는 데 활용할 수 있기를 기대한다.

참 고 문 헌

1. 국내문헌

- 강현민, 이현섭. (2020). 국내 프로야구 타자의 경기력과 FA제도 적용에 관한 연구. 한국체육학회지, 제59권 제6호, 289-301.
- 남준우. (2000). 비모수커널추정법에 의한 확률밀도함수의 추정. 계량경제학보, 11(4), 105-121.
- 박재용. (2016). Science Plus 스포츠과학 ; 운동선수 스포츠 손상 및 재활의 적용. 스포츠과학, 134, 36-43.
- 변경석. (2019). 야구 투수의 투구 유형 및 구종에 따른 상지 움직임의 생체역학적 이해와 어깨 및 팔꿈치 관절의 상해 요인 분석. 성균관대학교 일반대학원 박사학위논문.
- 송문구, 전일우, 강현식. (2022). 한국 프로야구 선수들의 정규 시즌 중 부상 분석: 파일럿 스터디. Koean Society of Exercise Physiology, Vol.31, No.2, 257-263.
- 이용수, 김용래, 임태홍. (2015). 야구 경기력 평가 분석을 위한 개념구조탐색. 한국체육학회지, Vol.24, No.3, 535-546.

2. 외국문헌

- Alvarado, A., Sharp, R., Brown, A., White, E., Kusters, I. S., & Dean, J. M.

- (2021). MLB Statcast Pitch Analysis: the Association between Active Spin and Opponent's Batting Average. In *International Journal of Exercise Science: Conference Proceedings* (Vol. 2, No. 13, p. 50).
- Batista, G. E., Prati, R. C., & Monard, M. C. (2004). A study of the behavior of several methods for balancing machine learning training data. *ACM SIGKDD explorations newsletter*, 6(1), 20-29.
- Bergstra, J., Bardenet, R., Bengio, Y., & Kégl, B. (2011). Algorithms for hyper-parameter optimization. *Advances in neural information processing systems*, 24.
- Drew Bennison, Mallet James. (2021). Predicting MLB Pitcher Injuries With Statcast Data. <https://github.com/drewbennison/Pitcher-Injuries>
- Eric C. Makhni, MD, Randall W. Lee, BS, Zachary S. Morrow, BS, Anthony P. Gualtieri, BS, Prakash Gorroochurn, PhD, and Christopher S. Ahmad, MD, (2014). Performance, Return to Competition, and Reinjury After Tommy John Surgery in Major League Baseball Pitchers. *The American Journal of Sports Medicine*, Vol. 42, No. 6.
- Erickson, B. J., Chalmers, P. N., Bush-Joseph, C. A., & Romeo, A. A. (2016). Predicting and preventing injury in Major League Baseball. *Am J Orthop*, 45(3), 152-156.
- Fury, M., Scarborough, D., Oh, L., Wright-Chisem, J., Fury, J., & Berkson, E. (2021). Performance Analytics and Pitch Metrics as Predictors of Ulnar Collateral Ligament Injury in Major League Baseball Pitchers (128). *Orthopaedic Journal of Sports Medicine*, 9(10_suppl5), 2325967121S00271.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9), 1263-1284.

- Hibberd, E. E., Brown, J. R., & Hoffer, J. T. (2015). Optimal management of ulnar collateral ligament injury in baseball pitchers. *Open access journal of sports medicine*, 343-352.
- J. F. Donges, Y. Zou¹, N. Marwan¹ and J. Kurths, (2009). The backbone of the climate network. *Europhysics Letters Association*, Volume 87, Number 4.
- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical transactions of the royal society A: Mathematical, Physical and Engineering Sciences*, 374(2065), 20150202.
- Karakolis, T., Bhan, S., & Crotin, R. L. (2013). An inferential and descriptive statistical examination of the relationship between cumulative work metrics and injury in Major League Baseball pitchers. *The Journal of Strength & Conditioning Research*, 27(8), 2113-2118.
- Kracker, D., Garcke, J., Schumacher, A., & Schwanitz, P. (2020). Automatic analysis of crash simulations with dimensionality reduction algorithms such as PCA and t-SNE. In *16th International LS-DYNA Users Conference*.
- LaPrade, C. M., Cinque, M. E., Safran, M. R., Freehill, M. T., Wulf, C. A., & LaPrade, R. F. (2022). Using advanced data to analyze the impact of injury on performance of major league baseball pitchers: a narrative review. *Orthopaedic journal of sports medicine*, 10(7), 23259671221111169.
- Mateusz Buda, Atsuto Maki, Maciej A. Mazurowski, (2018). A systematic study of the class imbalance problem in convolutional neural networks. *Neural Networks*, 106:249 - 259, 2018.
- Mohammed, R., Rawashdeh, J., & Abdullah, M. (2020). Machine learning with oversampling and undersampling techniques: overview study and

- experimental results. In 2020 11th international conference on information and communication systems (ICICS) (pp. 243–248). IEEE.
- Olsen, S. J., Fleisig, G. S., Dun, S., Loftice, J., & Andrews, J. R. (2006). Risk factors for shoulder and elbow injuries in adolescent baseball pitchers. *The American journal of sports medicine*, 34(6), 905–912.
- Raju, V. G., Lakshmi, K. P., Jain, V. M., Kalidindi, A., & Padma, V. (2020, August). Study the influence of normalization/transformation process on the accuracy of supervised classification. In 2020 Third International Conference on Smart Systems and Inventive Technology (ICSSIT) (pp. 729–735). IEEE.
- Shah, D., Singh, A., & Prasad, S. S. (2022). Sentimental Analysis Using Supervised Learning Algorithms. In 2022 3rd International Conference on Computation, Automation and Knowledge Management (ICCAKM) (pp. 1–6). IEEE.
- Węglarczyk, S. (2018). Kernel density estimation and its application. In ITM Web of Conferences (Vol. 23, p. 00037). EDP Sciences.
- Yann LeCun, Yoshua Bengio & Geoffrey Hinton. (2015). Deep learning. *Nature* 521, 436–444.

3. 기타참고자료

스포츠안전재단(Accessed November, 11, 2022). <https://www.sportsafety.or.kr>

Baseball savant (Accessed November, 11, 2022). <https://baseballsavant.mlb.com>

Github ‘jldbc/pybaseball’ (Accessed November, 11, 2022).
<https://github.com/jldbc/pybaseball>

Major league Baseball (Accessed November, 11, 2022). <https://www.mlb.com>

ABSTRACT

A Study on Predicting MLB Pitcher Injuries Using Statcast and Deep Learning

Minki Son

Department of Sport Interaction Science

Sungkyunkwan University

The issue of pitcher injuries in Major League Baseball (MLB) poses a significant challenge, adversely affecting not only the individual competitiveness but also the overall team performance. Although studies have been conducted on pitcher injuries in the past, most of them have focused more on identifying causes of injury after isolating specific groups and presenting baseline data for prevention, rather than directly predicting injuries.

Since 2015, the MLB has been offering numerous opportunities to observe various pitching outcomes and related characteristics through the introduction of the Statcast data tracking system. The objective of this study is to develop a deep learning model that predicts injuries using the extensive pitch quality data from Statcast, thereby aiming to protect pitchers from potential injury risks.

Based on the research findings, a deep learning model was developed to predict the probability of a pitcher being listed on the injury list within five

games after a certain game, using previously underutilized information such as 'horizontal and vertical pitch movement, pitch release point location and speed, and pitch location and spin rate in and out of the strike zone.' In addition, six different cases were classified to construct the model by considering crucial information like a pitcher's past injury history, thereby ensuring optimal predictive performance for each scenario.

The model demonstrated the highest 'Test Accuracy' at 94.7% in 'Case 6', which focused on players with experience of elbow medial ligament injury. This was followed by 'Case 5' with 93.6% for those who had an elbow injury, 'Case 3' with 93.3% for those with a shoulder injury, 'Case 2' with 93.1% for major upper body injuries, 'Case 4' with 92.1% for arm injuries, and 'Case 1' at 90.7% for the entire pitcher population.

In the 'Macro F1-Score', useful for dealing with class imbalance issues, 'Case 6' once again demonstrated the highest score at 0.741, followed by 'Case 5' at 0.693, 'Case 4' at 0.681, 'Case 2' at 0.647, 'Case 3' at 0.624, and 'Case 1' at 0.607.

Finally, another crucial performance evaluation tool for classification models, 'Evaluation using ROC curve and AUC', showed 'Case 6' having the highest AUC at 0.93, then 'Case 5' at 0.86, 'Case 4' at 0.85, 'Case 2' at 0.83, 'Case 1' at 0.81, and 'Case 3' at 0.80.

The model proposed in this paper holds promise in aiding the development of more precise pitcher injury prediction models in the future. Notably, the significant aspect of this model is that it leverages pitching data that can be easily collected by MLB player managers and team stakeholders to forecast injuries. This study has presented a novel injury prediction methodology using deep learning and Statcast data, and it is expected to bring about substantial

changes in managing pitcher injuries and strategizing in the MLB in the future.

Keywords: Pitcher Injury Prediction, Statcast, Supervised Learning, Deep Learning, Feedforward Neural Network, Imbalanced Data